

BACHELORARBEIT

Fachbereich Informatik

VERTRAUEN DURCH VALIDIERUNG

Eine quantitative Evaluation der Robustheit und
Erklärungstreue von XAI-Methoden bei der
dermatologischen Bildklassifikation auf dem
HAM10000-Datensatz

Vorgelegt von:

Christopher Böhm

Matrikelnummer: 860066

Studiengang: Informatik

Abgabetermin: 28.06.2026

Betreuer: Dr.-Ing. Eric MSP Veith

Abstract

Moderne Deep-Learning-Modelle erzielen in der Dermatologie eine diagnostische Genauigkeit auf Facharztniveau, agieren klinisch allerdings meist als intransparente „Black-Boxes“. Um das notwendige Vertrauen für den Praxiseinsatz zu schaffen, bieten Methoden der erklärbaren KI (XAI) visuelle Erklärungen in Form von Heatmaps. Bislang fehlt es in der Forschung jedoch an kontrollierten, quantitativen Vergleichen, die die Zuverlässigkeit dieser Erklärungsansätze unter konstanten Bedingungen isoliert messen.

Das Ziel dieser Bachelorarbeit ist ein methodisch empirischer Vergleich zweier gegensätzlicher XAI-Verfahren auf dem HAM10000-Datensatz: dem gradientenbasierten Verfahren Grad-CAM und der perturbationsbasierten Methode LIME. Beide Ansätze werden architekturübergreifend auf dem komplexen Modell ResNet-101 sowie dem effizienten Modell MobileNetV3 evaluiert. Die Erklärungsqualität wird über das Quantus-Framework anhand der Kriterien Robustheit (Local Lipschitz Estimate), Erklärungstreue (IROF) und Recheneffizienz objektiv gemessen. Ergänzend wird über qualitative Sanity Checks untersucht, wie gut die Methoden Fehlklassifikationen nachvollziehen und Verzerrungen durch den „Clever Hans“-Effekt offenlegen.

Die quantitativen Ergebnisse zeigen deutliche Unterschiede: Grad-CAM ist robust gegenüber Bildrauschen und arbeitet echtzeitfähig ($\sim 0,01$ s). Seine Erklärungstreue bricht jedoch auf dem MobileNetV3 ein, da dessen ressourcenschonende Faltungen den internen Gradientenfluss verzerren. LIME hingegen liefert auf dem MobileNetV3 treuere Erklärungen, zeigt jedoch eine starke Instabilität bei minimalen Bildstörungen und unpraktikabel lange Rechenzeiten. Die Arbeit kommt zu dem Schluss, dass für eine vertrauenswürdige Diagnose neben der passenden Kombination aus Modellarchitektur und XAI-Verfahren auch eine visuelle Begutachtung der Heatmaps zwingend notwendig ist, um Fehlentscheidungen durch Hintergrundartefakte zu verhindern.

Inhaltsverzeichnis

1. Einleitung	1
1.1 Motivation und Problemstellung	1
1.2 Zielsetzung und Forschungsfrage	2
1.3 Aufbau der Arbeit	4
2. Theoretische Grundlagen	6
2.1 Convolutional Neural Network.....	6
2.1.1 ResNet-101	9
2.1.2 MobileNetV3.....	10
2.2 Transfer Learning	11
2.3 Explainable Artificial Intelligence.....	12
2.3.1 Grad-CAM.....	13
2.3.2 Lime	15
2.3.3 Alternative XAI-Methoden.....	17
2.4 Evaluierungskriterien für XAI.....	18
2.4.1 Erklärungstreue (Faithfulness)	18
2.4.2 Robustheit (Robustness)	19
2.4.3 Recheneffizienz und Verständlichkeit (Klinische Anwendbarkeit).....	20
3. Datengrundlage und Modelltraining.....	21
3.1 Der HAM10000 Datensatz.....	21
3.2 Datenvorbereitung, Augmentierung und Splitting	23
3.2.1 Datensplit und Stratified Sampling	24
3.2.2 Methodischer Umgang mit der Klassenimbalance.....	24
3.2.3 Bildskalierung und Normalisierung	26
3.2.4 Datenaugmentierung	26
3.3 Hyperparameter und Modelloptimierung.....	27
3.3.1 Verlustfunktion und Optimierungsalgorithmus.....	28
3.3.2 Steuerung der Lernrate (Learning Rate Scheduling).....	29
3.3.3 Batch-Size, Dropout und Early Stopping	29
3.4 Durchführung des Transfer Learnings.....	30
4. Methodik und experimenteller Ablauf	31
4.1 Begründung der XAI-Methodenauswahl.....	31
4.2 Software-Infrastruktur und Evaluierungsframework.....	32

4.2.1 Deep-Learning-Basis.....	32
4.2.2 Frameworks zur XAI-Generierung.....	32
4.2.3 Quantitative Evaluation: Das Quantus-Framework.....	33
4.2.4 Hardware-Infrastruktur	33
4.3 Experimenteller Ablauf: Modellvorhersage und Erklärungsgenerierung.....	34
4.3.1 Bestimmung der Modell-Performance und XAI-Testdatenaufteilung.....	34
4.3.2 Erklärungsgenerierung mittels Grad-CAM	34
4.3.3 Erklärungsgenerierung mittels LIME.....	35
4.3.4 Experimentelles Design und Parameter-Variation.....	35
4.4 Quantitative Evaluierungsmetriken.....	36
4.4.1 Erklärungstreue	37
4.4.2 Robustheit	37
4.4.3 Komplexität und Effizienz (Klinische Anwendbarkeit).....	38
4.5 Qualitative Sanity Checks und Fehleranalyse.....	39
4.5.1 Fehleranalyse im klinischen Kontext (False Positives / False Negatives)...	39
4.5.2 Identifikation von Artefakten und dem "Clever Hans"-Effekt	40
4.6 Statistische Auswertung	40
5. Ergebnisse.....	41
5.1 Modell-Performance (Klassifikationsgüte).....	41
5.2 Robustheit.....	44
5.2.1 Basis-Vergleich der XAI-Methoden (Durchlauf 4).....	44
5.2.2 Parametersensitivität – LIME (Durchlauf 4, 5, 6, 7, 8)	45
5.2.3 Sensitivität der Evaluierungsmetrik – Local Lipschitz Estimate (Durchlauf 1, 2, 3, 4, 9, 10)	47
5.3 Erklärungstreue	47
5.3.1 Basis-Vergleich der XAI-Methoden (Durchlauf 4).....	47
5.3.2 Parametersensitivität – LIME (Durchlauf 4, 5, 6, 7, 8)	49
5.4 Recheneffizienz und klinische Anwendbarkeit.....	50
5.4.1 Basis-Vergleich und Architektureinfluss.....	50
5.4.2 Einfluss der LIME-Parameter auf die Effizienz	52
5.5 Qualitative Sanity Checks (Fehleranalyse).....	53
5.6 Modellabhängigkeit der erlernten Repräsentationen	54
6. Diskussion	55
6.1 Interpretation der Klassifikationsleistung als Ausgangsbasis.....	55
6.2 Beantwortung der Forschungsfragen.....	55

6.2.1 Robustheit.....	55
6.2.2 Erklärungstreue.....	56
6.2.3 Recheneffizienz und klinische Anwendbarkeit.....	57
6.3 Qualitative Erkenntnisse und der "Clever Hans"-Effekt.....	59
6.4 Limitationen der Arbeit.....	60
7. Fazit und Ausblick.....	61
7.1 Zusammenfassende Schlussfolgerungen der XAI-Evaluation.....	61
7.2 Klinische Implikationen und der Wert der Erklärbarkeit.....	62
7.3 Zukünftiger Forschungsbedarf (Ausblick).....	63
Anhang.....	65
A.1 Quellcode und Reproduzierbarkeit.....	65
A.2 Entwurf der klinischen Software-Oberfläche (Mockup).....	65
Literaturverzeichnis.....	67

1. Einleitung

1.1 Motivation und Problemstellung

In den vergangenen Jahren hat der Einsatz von Deep-Learning-Modellen, insbesondere von Convolutional Neural Networks (CNNs), zu erheblichen Fortschritten in der medizinischen Bildanalyse geführt [1]. Ein hochrelevantes Anwendungsfeld ist dabei die automatisierte Klassifikation von Hautläsionen zur Unterstützung der Hautkrebsdiagnostik [2]. Trainiert auf umfangreichen und standardisierten Bildsammlungen wie dem HAM10000-Datensatz [3], erreichen moderne CNNs mittlerweile Genauigkeiten, die mit der diagnostischen Leistung menschlicher Dermatologen vergleichbar sind oder diese sogar übertreffen [4].

Trotz dieses technologischen Potenzials zeigt sich in der medizinischen Praxis ein zentraler Konflikt: Die hohe Klassifikationsleistung dieser Modelle geht mit einem fast vollständigen Verlust an Nachvollziehbarkeit einher [5]. Dass die Arbeitsweise des Modells verborgen bleibt, blockiert den Einsatz in der Praxis. Ärzte haben die Letztverantwortung für ihre Patienten und können einer Software nicht ohne Weiteres glauben. Das funktioniert nur, wenn die logischen Argumente hinter der Diagnose für den Arzt sichtbar und überprüfbar sind [6]. Verschärft wird diese Problematik durch aktuelle rechtliche Rahmenbedingungen, wie die europäische Datenschutz-Grundverordnung (DSGVO), die ein Recht auf Erklärbarkeit bei automatisierten Entscheidungen verlangt. Wer eine solche KI zudem als klinisches Assistenzsystem (Clinical Decision Support System) in Krankenhäusern einsetzen möchte, muss sich primär nach der *Medical Device Regulation (MDR)* richten [6]. Da CDSS rechtlich als Medizinprodukte gelten, macht die MDR Transparenz und Nachvollziehbarkeit zur Voraussetzung für eine erfolgreiche Zulassung. Hierdurch stößt der Einsatz reiner Black-Box-Modelle zunehmend auch rechtlich an seine Grenzen [7, 8].

Als technologische Antwort auf dieses Vertrauensproblem hat sich das Forschungsfeld der *Explainable Artificial Intelligence (XAI)* stark entwickelt [8]. Sogenannte Post-hoc-Methoden versuchen, die Black-Box nachträglich zu durchleuchten, indem sie beispielsweise in Form von Heatmaps visuell aufzeigen, welche Bildbereiche für die Diagnose ausschlaggebend waren [9]. In der Praxis dominieren hierbei unter anderem zwei grundlegend verschiedene Herangehensweisen: gradientenbasierte Ansätze wie Grad-CAM, die auf den Aktivierungsgradienten des Modells beruhen [10], sowie perturbationsbasierte Verfahren wie LIME. Sie verfälschen das Originalbild systematisch an einzelnen Stellen, um so die Entscheidung des Modells Schritt für Schritt nachzuvollziehen [11].

Aus dieser methodischen Vielfalt ergibt sich jedoch die zentrale Problemstellung der vorliegenden Arbeit. Obwohl Heatmaps intuitiv verständlich wirken, warnt die aktuelle Forschung zunehmend davor, dass XAI-Verfahren anfällig für Artefakte sind und die Modelle in Wahrheit oft nur triviale Störfaktoren erlernen, was bei einer rein visuellen, subjektiven Begutachtung der Heatmaps unentdeckt bleiben kann [12, 13, 14]. Zwar adressieren erste Studien, wie etwa die Arbeit von Sangwan (2024) [15], diese Lücke durch die Einführung quantitativer Evaluationsmetriken auf dem HAM10000-Datensatz, um Aspekte wie Erklärungstreue und Robustheit objektiv zu messen. Da derartige Studien jedoch meist als breite Benchmarks über eine Vielzahl von Modellarchitekturen und Hyperparametern hinweg angelegt sind, bleibt in der aktuellen Forschungsliteratur eine entscheidende Frage oft unbeantwortet: Es fehlt an einem detaillierten, kontrollierten und isolierten Vergleich der fundamentalen Grundkonzepte – also gradienten- versus perturbationsbasierte Methoden – unter konstanten Modellbedingungen.

Wenn man das Vertrauen in KI-Diagnosen im dermatologischen Alltag langfristig festigen möchte, muss man die Zuverlässigkeit dieser unterschiedlichen Erklärungsansätze unvoreingenommen und anhand konkreter Messwerte überprüfen können.

1.2 Zielsetzung und Forschungsfrage

Aufbauend auf der zuvor identifizierten Forschungslücke ist das primäre Ziel dieser Bachelorarbeit, einen methodisch kontrollierten, empirischen Vergleich zweier konzeptionell grundverschiedener XAI-Methoden im Kontext der dermatologischen Bildklassifikation durchzuführen. Während bisherige Arbeiten in der medizinischen Bildverarbeitung die Qualität von XAI-generierten Erklärungen (Heatmaps) oft nur durch eine subjektive, visuelle Inspektion durch Fachexperten bewerten, strebt diese Arbeit eine objektive, quantifizierbare Evaluierung an.

Durch ein festes Versuchsdesign mit standardisierten Bedingungen sollen die genauen Unterschiede bei der Erstellung der Heatmaps isoliert und exakt gemessen werden. Um die Funktionsweise medizinischer KI-Systeme verlässlich zu prüfen, soll die folgende zentrale Forschungsfrage beantwortet werden:

Inwiefern unterscheiden sich gradientenbasierte (z. B. Grad-CAM) und perturbationsbasierte (z. B. LIME) XAI-Methoden hinsichtlich ihrer Robustheit und Erklärungstreue bei der Klassifikation des HAM10000-Datensatzes?

Zur systematischen und strukturierten Beantwortung dieser Hauptforschungsfrage wird die Untersuchung in drei konkrete Teilfragen (Forschungsziele) untergliedert, die sich an etablierten XAI-Evaluierungsmetriken orientieren:

1. Robustheit (Robustness): Wie stark variieren die von den XAI-Methoden generierten Erklärungen (Heatmaps) bei künstlich herbeigeführten Bildtransformationen, sofern die eigentliche Vorhersage des Modells unverändert bleibt?

Die Robustheit bewertet die Stabilität einer Erklärung gegenüber geringfügigen Störungen (Perturbationen) im Eingabebild [16]. In der klinischen Praxis können dermatoskopische Bilder durch unterschiedliche Lichtverhältnisse, leichtes Sensorrauschen oder abweichende Aufnahmewinkel variieren [17]. Wenn ein Modell trotz dieser Transformationen dieselbe korrekte Klassifikation stellt, fordert das Kriterium der Robustheit, dass auch die Heatmap konsistent bleiben muss und sich nicht drastisch verändert [16]. Zur Beantwortung dieser Teilfrage wird quantitativ untersucht, welche der beiden XAI-Methoden resistenter gegenüber solchen Störfaktoren ist.

2. Erklärungstreue (Faithfulness): Korrelieren die von der jeweiligen XAI-Methode als wichtig markierten Bildbereiche tatsächlich mit dem internen Klassifikationsergebnis des Modells?

Die Erklärungstreue misst, wie präzise eine Erklärung den wahren internen Entscheidungsprozess des KI-Modells widerspiegelt. Eine Heatmap kann für das menschliche Auge zwar überzeugend und medizinisch plausibel wirken, jedoch technisch inkorrekt sein, wenn das Modell seine Entscheidung in Wahrheit auf ganz andere Pixel stützt.

3. Klinische Anwendbarkeit: Welche der beiden Methoden bietet den besseren Kompromiss aus Recheneffizienz und Verständlichkeit im Hinblick auf einen potenziellen klinischen Einsatz?

Neben der rein technischen Korrektheit müssen XAI-Systeme auch Anforderungen im klinischen Alltag erfüllen [6]. Da medizinische Entscheidungen zeitkritisch sein können, darf die Wartezeit auf eine Erklärung den klinischen Workflow nicht blockieren [18]. Daher wird die Praxistauglichkeit der Verfahren vergleichend bewertet.

1.3 Aufbau der Arbeit

Um die zuvor formulierten Forschungsfragen systematisch und fundiert zu beantworten, ist die vorliegende Bachelorarbeit in sieben aufeinander aufbauende Kapitel gegliedert.

Nachdem in **Kapitel 1** die Motivation, die Problemstellung sowie die primäre Zielsetzung der Arbeit dargelegt wurden, schafft **Kapitel 2** die theoretischen Voraussetzungen. Zunächst wird die Funktionsweise von Convolutional Neural Networks (CNNs) erläutert, wobei die beiden für diese Arbeit zentralen Architekturen – ResNet-101 und MobileNetV3 – sowie das Konzept des Transfer Learnings im Detail vorgestellt werden. Im Anschluss erfolgt eine Einführung in das Forschungsfeld der Explainable Artificial Intelligence (XAI) mit besonderem Fokus auf die Methoden Grad-CAM und LIME.

Abschließend werden die zur Evaluation herangezogenen Kriterien definiert: Erklärungstreue, Robustheit sowie die Recheneffizienz für die klinische Anwendbarkeit.

Kapitel 3 widmet sich der Datengrundlage sowie der praktischen Vorbereitung und Optimierung der Modelle. Nach der Vorstellung des HAM10000-Datensatzes werden die Strategien zur Datenaufbereitung – einschließlich Datensplitting, Augmentierung und dem methodischen Umgang mit der Klassenimbalance – detailliert erläutert. Darauf aufbauend werden die gewählten Hyperparameter definiert, bevor abschließend die konkrete Durchführung des Transfer Learnings beschrieben wird. In **Kapitel 4** wird die Methodik der durchgeführten quantitativen Evaluation spezifiziert. Das Kapitel beschreibt den experimentellen Ablauf, die Software-Infrastruktur sowie die exakten quantitativen Metriken zur standardisierten Messung von Erklärungstreue, Robustheit und klinischer Effizienz, ergänzt durch die statistischen Verfahren zur Überprüfung von Signifikanz und praktischer Bedeutsamkeit.

Kapitel 5 präsentiert die empirischen Ergebnisse der XAI-Evaluation. Hier werden neben der Modell-Performance von ResNet-101 und MobileNetV3 die ermittelten Metrik-Werte für Grad-CAM und LIME auf den beiden trainierten CNN-Architekturen objektiv gegenübergestellt, die generierten Heatmaps visualisiert und die quantitativen Befunde durch qualitative Sanity Checks (Fehleranalysen) ergänzt.

Auf Basis dieser erhobenen Daten erfolgt in **Kapitel 6** eine umfassende und kritische Diskussion. Die experimentellen Resultate werden interpretiert, um die zentralen Forschungsfragen zu beantworten und die XAI-Methoden im Spannungsfeld zwischen technischer Zuverlässigkeit, Stabilität und praktischer Anwendbarkeit im klinischen Alltag zu bewerten, bevor das Kapitel mit einer kritischen Reflexion der methodischen Limitationen dieser Arbeit abschließt.

Abschließend fasst **Kapitel 7** die zentralen Erkenntnisse der Untersuchung in einem Fazit zusammen. Zudem werden die klinischen Folgen für den medizinischen Alltag beleuchtet und konkrete Ausblicke auf zukünftige Forschungsmöglichkeiten im Bereich der Validierung medizinischer KI-Systeme gegeben.

2. Theoretische Grundlagen

Dieses Kapitel legt die theoretischen und methodischen Fundamente für die vorliegende Arbeit. Da die automatisierte Klassifikation von Hautläsionen auf komplexen Deep-Learning-Verfahren basiert, wird zunächst die Funktionsweise von Convolutional Neural Networks (CNNs) sowie der in dieser Arbeit verwendeten Architekturen ResNet-101 und MobileNetV3 erläutert. Um derartige Netzwerke trotz begrenzter medizinischer Trainingsdaten effektiv anpassen zu können, wird im Anschluss das Prinzip des Transfer Learnings vorgestellt.

Da diese tiefen Modelle aufgrund ihrer Struktur oftmals als intransparente „Black-Boxes“ agieren, widmet sich der dritte Teil des Kapitels der Explainable Artificial Intelligence (XAI). Hierbei werden die zugrundeliegenden Konzepte von Grad-CAM und LIME detailliert beschrieben sowie prominente alternative Verfahren rein beispielhaft skizziert, um die methodische Bandbreite des Forschungsfeldes aufzuzeigen.

Abschließend werden in Kapitel 2.4 die Evaluierungskriterien definiert. Dazu zählen die mathematischen Metriken zur Messung der Erklärungstreue (IROF) und Robustheit (Local Lipschitz Estimate) sowie das Kriterium der Recheneffizienz, welche zusammen das Fundament für die spätere quantitative Überprüfung der XAI-Methoden im klinischen Kontext bilden.

2.1 Convolutional Neural Network

Convolutional Neural Networks (CNNs) sind tiefe künstliche neuronale Netze, die speziell für die Verarbeitung gitterförmiger Daten wie digitaler Bilder konzipiert wurden [19]. Im Gegensatz zu klassischen, vollständig vernetzten Netzen betrachten CNNs nicht alle Bildpunkte gleichzeitig, sondern werten immer nur kleine, direkt benachbarte Bildbereiche aus. Dadurch erkennen sie Bildmuster Schritt für Schritt und sparen dabei viel Rechenleistung. Die Architektur ist von der Arbeitsweise des visuellen Kortex inspiriert. Ihr Kern besteht aus einer abwechselnden Abfolge von Faltungs- und Pooling-Schichten, an welche sich abschließend eine vollständig vernetzte Schicht anreicht. [19]:

1. **Convolutional Layer (Faltungsschicht):** Im Zentrum des Netzwerks stehen Filtermatrizen, auch Kernel genannt, die das Eingangsbild systematisch abtasten [19]. Hierbei scannt die Filtermatrix das Eingabebild durch elementweise Multiplikation und Summation, um lokale Feature Maps zu extrahieren [19]. Eine solche Feature Map setzt sich aus den Ausgabewerten einer zweidimensionalen Anordnung künstlicher Neuronen zusammen [19]. Ein einzelnes Neuron entspricht in diesem Kontext der Anwendung des Filters auf einen lokalen Bildausschnitt (das sogenannte rezeptive Feld) [19]. Da alle Neuronen innerhalb derselben Feature Map nach dem gleichen visuellen Muster suchen, teilen sie sich exakt dieselben Filtergewichte [19].

Mathematisch betrachtet berechnet jedes dieser Neuronen ein Skalarprodukt aus den Eingabewerten seines rezeptiven Feldes und diesen geteilten Gewichten, woraufhin ein Bias-Term addiert wird [19]. Die daraus resultierende gewichtete Summe a_i für ein Neuron i ist definiert als:

$$a_i = \sum_j u_{ij} x_j + b_i$$

Formel 1: Berechnung der gewichteten Summe für das lokale rezeptive Feld eines Neurons. (Quelle: LeCun et al., 1998 [19])

Dabei ist u_{ij} das Gewicht der Verbindung vom vorgeschalteten Neuron j zum betrachteten Neuron i , x_j der Zustand des vorgeschalteten Neurons und b_i der addierte Bias [19]. Die gewichtete Summe a_i wird anschließend durch eine Aktivierungsfunktion f geleitet, um den finalen Ausgabezustand $x_i = f(a_i)$ zu berechnen [19]. Die resultierende Feature Map ist somit eine zweidimensionale "Karte", die genau dokumentiert, an welchen Bildpositionen und wie stark ein bestimmtes Muster dort ausgeprägt ist [19]. Durch diesen Vorgang extrahiert das Modell aufeinander aufbauende Merkmale [19]. Während die frühen Schichten vor allem grundlegende Strukturen wie Kanten erfassen, erkennen die tieferen Ebenen zunehmend relevante Details wie spezifische Läsionsformen oder Pigmente.

2. **Pooling Layer:** In den Pooling-Schichten werden benachbarte Bildpunkte zusammengefasst, um die räumliche Auflösung zu reduzieren [19]. Während frühe Modelle nach LeCun et al. (1998) hierfür noch Durchschnittswerte und Sigmoid-Funktionen nutzten, hat sich in modernen CNN-Architekturen das *Max-Pooling* etabliert [20]. Es leitet lediglich die stärkste Aktivierung weiter, was Parameter spart und das Modell robuster gegenüber räumlichen Verschiebungen macht [21]. Zudem wird anstelle von Sigmoid-Funktionen heute standardmäßig die *Rectified Linear Unit (ReLU)* als Aktivierungsfunktion eingesetzt, um das Training tiefer Netze effizienter und stabiler zu gestalten.
3. **Fully Connected Layer (Vollständig vernetzte Schicht):** Sobald das Netzwerk alle wichtigen Muster extrahiert hat, ordnet es die verdichteten Bildinformationen zu einem Vektor an [19]. In dieser letzten Verarbeitungsstufe wägt das Modell ab, wie stark jedes einzelne Merkmal für die endgültige Entscheidung ins Gewicht fällt [19]. Während historische Modelle hierfür noch euklidische RBF-Einheiten (Radial Basis Function) verwendeten, ist dieser Ansatz heute obsolet. Der aktuelle Standard für die finale Klassifikation ist die *Softmax-Funktion*. Sie wandelt die Werte der vorletzten Schicht in eine direkt interpretierbare Wahrscheinlichkeitsverteilung um [22].

Mathematisch wird die finale Wahrscheinlichkeit y^c für eine bestimmte Diagnoseklasse c berechnet, indem die Exponentialfunktion des Klassenscores s^c durch die Summe der Exponentialwerte k aller möglichen Klassen normalisiert wird:

$$4. \quad y^c = \frac{\exp(s^c)}{\sum_k \exp(s^k)}$$

Formel 2: Mathematische Definition der Softmax-Funktion. (Quelle: Chattopadhyay et al., 2018)

Durch diese Normalisierung addieren sich alle Ausgabe-Wahrscheinlichkeiten des Modells exakt zu 100 % (bzw. 1,0) auf, wobei die Klasse mit dem höchsten Ausgabewert die finale Diagnose des Netzwerks ist [23].




Abbildung 1: Schematische Darstellung der Standard-Architektur eines Convolutional Neural Networks. (Eigene Darstellung in Anlehnung an LeCun et al., 1998 [23])

Das Training dieser Netzwerke basiert auf überwachtem Lernen [19]. Über Algorithmen wie Backpropagation und Gradientenabstieg passt das Modell seine Filtergewichte iterativ so an, dass die Abweichung zwischen der errechneten Vorhersage und der echten Klassifikation stetig sinkt [19]. Mathematisch lässt sich dieser Gradientenabstieg so beschreiben, dass der Parametervektor W in jedem Iterationsschritt k entlang des negativen Gradienten der Fehlerfunktion $E(W)$ aktualisiert wird. Die formale Anpassungsregel lautet dabei [19]:

$$W_k = W_{k-1} - \epsilon \frac{\partial E(W)}{\partial W}$$

Formel 3: Mathematische Definition der iterativen Parameteranpassung mittels Gradientenabstieg. (Quelle: LeCun et al., 1998 [19])

Dabei bestimmt die Konstante ϵ die exakte Schrittweite (Lernrate) der iterativen Anpassung [19]. Dadurch liefert das Netzwerk am Ende eine präzise Entscheidung.

2.1.1 ResNet-101

Historisch betrachtet stagniert die Genauigkeit tiefer neuronaler Netze oft und verschlechtert sich anschließend rapide. Dieses sogenannte Degradationsproblem ist nicht auf Overfitting, sondern auf grundlegende Optimierungsschwierigkeiten zurückzuführen [24]. Je tiefer ein Netz ist, desto stärker schwinden die Fehlergradienten auf dem Rückweg (Vanishing Gradient Problem), sodass sich die vorderen Gewichte kaum noch verändern und das Modell nichts mehr lernt.

Die von He et al. (2016) [24] eingeführte ResNet-Architektur löst dieses Problem durch Shortcut-Connections, die zusätzlich zu den regulären Schichten existieren. Anstatt eine komplexe Zielabbildung von Grund auf zu erlernen, passen die Schichten lediglich eine Restfunktion $F(x)$ an. Durch die direkte elementweise Addition der unveränderten Eingabe lautet die finale Ausgabe der Schicht:

$$y = F(x) + x$$

Formel 4: Berechnung der Ausgabe eines Residual-Blocks durch elementweise Addition der Eingabe zur erlernten Restfunktion. (Quelle: He et al., 2016 [24])

Während beim Lernen beide Wege parallel durchlaufen werden, entfalten diese Shortcuts ihren Hauptnutzen vor allem während der Backpropagation. Diese Shortcuts wirken dem Problem des verschwindenden Gradienten entgegen, da der Fehlergradient die transformierenden Schichten umgehen und stabil durch das tiefe Modell fließen kann [24]. Muss eine Schicht die Eingabe nur unverändert weitergeben, drückt der Algorithmus die Gewichte der Restfunktion einfach gegen null ($F(x) \approx 0$), was mathematisch leichter zu erlernen ist [24].




Abbildung 2: Schematische Darstellung eines Residual-Blocks. (Quelle: He et al., 2016, S. 771 [24])

Speziell für die automatische Erkennung von Hautläsionen hat sich das ResNet in der Wissenschaft als ein leistungsfähiges Modell bewährt. Aktuelle Untersuchungen zeigen, wie leistungsfähig diese Struktur bei der Analyse von Hautbildern ist. So konnten Han et al. (2023) mit einem auf dem ResNet-101 basierenden System eine Genauigkeit von 97,3 % erreichen [25]. In dieser Arbeit steht das ResNet-101 daher für den schweren, großen Modellansatz, dessen Hauptziel die maximale Genauigkeit bei der Klassifikation ist.

2.1.2 MobileNetV3

Im direkten Kontrast zum ResNet wurde die MobileNet-Architekturfamilie primär für den Einsatz auf mobilen und ressourcenbeschränkten Geräten entwickelt [26]. Dies ist insbesondere für die moderne Telemedizin von höchster Relevanz, in der Smartphone-gekoppelte Echtzeit-Diagnosen direkt am Patienten liefern sollen. Um diese Effizienz zu erreichen, verzichtet das MobileNet auf klassische Faltungen und nutzt stattdessen *Depthwise Separable Convolutions* [26, 27].

Anstelle einer standardmäßigen Faltung zerlegt die *Depthwise Separable Convolution* den Filterprozess in zwei separate Operationen [26]. Zunächst wendet eine *depthwise Convolution* exakt einen räumlichen Filter $\hat{K}$ auf jeden einzelnen Eingabekanal an [26]. Die Ausgabe $\hat{G}_{k,l,m}$ an der Position (k, l) für den m -ten Kanal der Eingangs-Feature-Map F wird berechnet als:

$$\hat{G}_{k,l,m} = \sum_{i,j} \hat{K}_{i,j,m} * F_{k+i-1,l+j-1,m}$$

Formel 5: Berechnung der Depthwise Convolution für einen einzelnen Eingabekanal.
(Quelle: Howard et al., 2017 [26])

In einem zweiten Schritt kombiniert eine 1x1-Faltung (Pointwise Convolution) diese gefilterten Kanäle linear zu neuen Merkmalen [26]. Der Vorteil dieses zweistufigen Verfahrens liegt in der Reduktion der Parameter und Rechenoperationen [26].

Um die Leistungsfähigkeit des Modells trotz dieser Parameterreduktion zu erhalten, integriert die Architektur sogenannte Squeeze-and-Excitation-Blöcke [28]. Diese Blöcke dienen als adaptive Filter zur Gewichtung der einzelnen Kanäle. Dafür aggregieren sie in der sogenannten „Squeeze“-Phase die räumlichen Informationen der Feature Maps durch Global Average Pooling zu einem einzigen statistischen Wert [28]. Darauf aufbauend lernt das Netzwerk in einer „Excitation“-Phase über vollvernetzte Schichten und eine Sigmoid-Aktivierung die spezifische Wichtigkeit dieser Kanäle, um aussagekräftige Merkmale gezielt zu verstärken und irrelevante Bildinformationen zu unterdrücken [28]. Dies trägt maßgeblich zur hohen Effizienz dieser Architektur bei (vgl. Abbildung 3).




Abbildung 3: Die Standard-Faltungsfilter in (a) werden durch zwei Schichten ersetzt: Tiefenfaltung in (b) und Punktfaltung in (c), um einen tiefenweise separierbaren Filter zu erzeugen. (Quelle: Howard A G et al. (2017) [26])

Trotz dieser ressourcenschonenden Architektur erzielten optimierte MobileNetV3-Modelle bei der Klassifikation von Hautläsionen wettbewerbsfähige Ergebnisse und können deutlich größere Modelle in puncto Effizienz übertreffen. So demonstrierten Lilhore et al. (2024) [29], dass eine auf MobileNetV3 basierende Hybrid-Architektur bei der Klassifikation von Hautläsionen auf dem HAM10000-Datensatz eine Genauigkeit von 98,86 % erreichen kann [29]. Es fungiert in dieser Arbeit somit als effizientes, ressourcenschonendes Pendant.

2.2 Transfer Learning

Tiefe neuronale Netze benötigen für das Training von Grund auf (Training from Scratch) in der Regel große Mengen an Trainingsdaten. In bestimmten Anwendungsfeldern, wie beispielsweise der medizinischen Bildanalyse, sind große und annotierte Datensätze jedoch oft selten [21]. Stehen für ein komplexes Klassifikationsproblem nur begrenzte Datenmengen zur Verfügung, führt ein Training mit zufällig initialisierten Gewichten schnell zu einem Overfitting.

Um dieses Problem zu umgehen, greift die Forschung auf das Prinzip des Transfer Learning zurück [30, 31]. Traditionelle Algorithmen des maschinellen Lernens gehen oft davon aus, dass Trainings- und Testdaten aus derselben Domäne stammen und dieselbe Verteilung aufweisen [31].

Das Transfer Learning weicht von dieser Annahme ab: Der Kerngedanke besteht darin, bereits erlerntes Wissen aus einer umfangreichen Quelldomäne zu extrahieren und auf eine neue, spezialisierte Zieldomäne zu übertragen [31].

Anstatt ein Modell bei null beginnen zu lassen, startet das Netzwerk mit vortrainierten Grundgewichten aus riesigen, allgemeinen Bildersammlungen, wie beispielsweise dem ImageNet-Datensatz [32]. Dieser Ansatz macht sich die hierarchische Arbeitsweise von CNNs zunutze. Durch das Vortraining verfügen die vorderen Netzwerkschichten bereits über optimale Filtergewichte zur zuverlässigen Erkennung grundlegender, universeller Strukturen wie Kanten, Formen und Kontraste [33]. Da diese visuellen Grundbausteine domänenübergreifend gültig sind, muss ein neues Netzwerk sie nicht noch einmal neu erlernen.

Um das vortrainierte Modell schließlich an die spezifische Klassifikation der Zieldomäne feinabzustimmen, wird die Architektur des Modells angepasst [31]. Die ursprünglichen Ausgabeschichten der Modelle werden dafür in der Regel entfernt und durch neue, Fully-Connected Layers ersetzt, die exakt auf die Zielkategorien ausgelegt sind [31]. Dieses Vorgehen ermöglicht ein stabiles Training und eine hohe Modellqualität, selbst wenn die Trainingsdaten der Zieldomäne begrenzt sind [31].

2.3 Explainable Artificial Intelligence

Die Explainable Artificial Intelligence (XAI) zielt darauf ab, die Entscheidungsprozesse komplexer Deep-Learning-Modelle für den Menschen nachvollziehbar zu gestalten, ohne Abstriche bei der Klassifikationsgenauigkeit in Kauf nehmen zu müssen [9]. Wie in der Einleitung (Kapitel 1.1) dargelegt, ist eine solche Transparenz im medizinischen Bereich von hoher Bedeutung. Sie bildet eine wichtige Voraussetzung für die Patientensicherheit [6] und wird zudem durch rechtliche Rahmenbedingungen wie die DSGVO gefordert, die verständlichen Erklärungen für automatisierte Diagnosen vorschreiben [7].

Um die Vielfalt der existierenden XAI-Verfahren systematisch einzuordnen, nutzt die Forschung üblicherweise drei zentrale Unterscheidungsmerkmale [9]:

1. **Intrinsische vs. Post-hoc-Erklärungen:** Intrinsische Modelle sind durch ihre simple Struktur von Grund auf für den Menschen verständlich. Ein Entscheidungsbaum arbeitet beispielsweise mit einer transparenten Abfolge von logischen Wenn-Dann-Fragen. Das ärztliche Personal kann auf dem Papier exakt ablesen, bei welchem konkreten Schwellenwert das System abbiegt und wie es Schritt für Schritt zu seinem Ergebnis gelangt. Bei komplexen CNNs kommen stattdessen Post-hoc-Verfahren zum Einsatz. Diese Methoden betrachten das fertige Netzwerk erst nach dem Training, um dessen verborgene Entscheidungsprozesse im Nachhinein zu entschlüsseln [9].

2. **Globale vs. Lokale Interpretierbarkeit:** Globale Ansätze beschreiben das allgemeine Wissen der KI über alle bekannten Daten hinweg. Sie zeigen also, auf welche Eigenschaften das Modell prinzipiell achtet, um Hautkrankheiten generell zu identifizieren. Lokale Methoden fokussieren sich im Gegensatz dazu auf eine einzige, ganz konkrete Klassifikation. Anhand eines individuellen Bild verdeutlichen sie detailgenau, welche spezifischen Pixel auf exakt diesem einen Bild ausschlaggebend dafür waren, dass das System die vorliegende Läsion beispielsweise als bösartig eingestuft hat [9].
3. **Modellspezifisch vs. Modellagnostisch:** Modellspezifische Verfahren sind auf eine bestimmte Netzwerkarchitektur zugeschnitten und benötigen Zugriff auf interne Modellparameter, wie beispielsweise die Gewichte oder Gradienten eines CNNs. Modellagnostische Ansätze hingegen behandeln das zu erklärende Modell als Black-Box und können architekturunabhängig auf jeden beliebigen Klassifikator angewendet werden [9].

Da in dieser Arbeit CNNs verwendet werden, wird die Fragestellung am besten mit Post-hoc-Methoden beantwortet. Sie liefern Ärzten die Begründung für die Klassifizierung einer individuellen Hautläsion.

2.3.1 Grad-CAM

Zu den etabliertesten modellspezifischen Post-hoc-Methoden für CNNs zählt das von Selvaraju et al. (2017) [10] entwickelte Gradient-weighted Class Activation Mapping, kurz Grad-CAM. Die Methode entstand als direkte Weiterentwicklung des ursprünglichen Class Activation Mapping (CAM) von Zhou et al. (2016) [34]. Der ältere Ansatz wies jedoch einen entscheidenden Nachteil auf, da er tiefgreifende Eingriffe in den Aufbau des Netzwerks verlangte. Beispielsweise mussten vollvernetzte Schichten durch ein Global Average Pooling ersetzt werden. Ein solches Vorgehen zog ein erneutes Training nach sich, was oft mit Leistungseinbußen einherging. Grad-CAM löst diese Problematik: Da es sich um ein Post-hoc-Verfahren handelt, lässt sich die Methode auf fertig trainierte Modelle wie ResNet oder MobileNet anwenden, ohne architektonische Anpassungen oder ein erneutes Training vorauszusetzen [10].

Die Funktionsweise stützt sich auf die mathematischen Gradienten, die während der Backpropagation ohnehin durch das Netzwerk geleitet werden [10]. Für die Auswertung greift der Algorithmus gezielt auf die allerletzte Faltungsschicht zu [10]. Diese allerletzte Schicht bietet ideale Voraussetzungen für eine visuelle Erklärung [10]. Einerseits enthält sie bereits stark abstrahierte Bildmerkmale wie die charakteristischen Strukturen eines Melanoms [10]. Andererseits bleiben auf dieser Stufe die räumlichen Zusammenhänge des ursprünglichen Bildes vollständig erhalten [10]. In den darauffolgenden vollvernetzten Schichten würden diese entscheidenden Positionsdaten unweigerlich gelöscht werden [10].

2. Theoretische Grundlagen

Um die klassenspezifische Heatmap $L_{Grad-CAM}^c$ für eine bestimmte Zielklasse c zu berechnen, leitet Grad-CAM zunächst den Vorhersagewert y^c (vor der Anwendung der Softmax-Funktion) nach den Feature Maps A^k der letzten Faltungsschicht ab [10]. Anschließend verdichtet ein Global Average Pooling diese zurückfließenden Gradienten über ihre räumlichen Dimensionen. [10]. Daraus ergibt sich der Gewichtungsfaktor α_k^c für jede Feature Map k :

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$$

Formel 6: Mathematische Berechnung der Gewichtungsfaktoren durch Global Average Pooling der Gradienten. (Quelle: Selvaraju et al., 2017 [10])

Dabei bezeichnet Z die Gesamtzahl der Pixel innerhalb dieser Map [10]. Das berechnete Gewicht α_k^c fasst die zurückfließenden Gradienteninformationen zusammen und quantifiziert so den direkten Einfluss der Feature Map k auf die Vorhersage der Zielklasse c [10]. Die finale Grad-CAM-Heatmap $L_{Grad-CAM}^c$ ergibt sich schließlich durch die Anwendung der ReLU-Funktion auf dieses Zwischenergebnis [10]:

$$L_{Grad-CAM}^c = ReLU\left(\sum_k \alpha_k^c A^k\right)$$

Formel 7: Mathematische Definition der finalen Grad-CAM-Heatmap als ReLU-gefilterte Linearkombination der Feature Maps. (Quelle: Selvaraju et al., 2017 [10])

Die ReLU-Funktion wird an dieser Stelle aus einem wichtigen Grund angewendet: Es sollen ausschließlich jene Merkmale farblich hervorgehoben werden, die einen positiven Einfluss auf die Klasse c haben [10]. Alles, was einen negativen Wert aufweist und somit für diese spezielle Entscheidung unwichtig ist oder sogar dagegen spricht, wird durch die Funktion herausgefiltert [10].




Abbildung 4: Schematische Funktionsweise von Grad-CAM. (Eigene Darstellung in Anlehnung an Selvaraju et al., 2017 [10])

Am Ende entsteht eine farbige Heatmap. Sie wird hochskaliert, sodass sie genau über das ursprüngliche Bild passt. Darauf zeigen warme Farben wie Rot und Gelb die Bereiche an, die für die Klassifikation der KI am wichtigsten waren [10]. Kühle Blautöne markieren hingegen die unwichtigen Stellen [10].

Obwohl Grad-CAM schnell arbeitet, hat das Verfahren für den klinischen Einsatz eine entscheidende Schwachstelle. Die Methode verlässt sich fundamental darauf, dass die sogenannten Gradienten stabil bleiben. Diese Gradienten messen, wie empfindlich das Modell auf kleinste Veränderungen im Eingabebild reagiert. Wie Alvarez-Melis und Jaakkola (2018) [16] jedoch belegen, können diese Gradienten stark schwanken. Durch diese Instabilität reicht bereits ein winziges, für das menschliche Auge unsichtbares Bildrauschen aus, um die visuelle Erklärung der KI zu verfälschen (vgl. Abbildung 11).

2.3.2 Lime

Als direkten Gegenentwurf zu Verfahren wie Grad-CAM entwickelten Ribeiro et al. (2016) die modellagnostische Methode LIME (*Local Interpretable Model-agnostic Explanations*) [11]. Die Methode betrachtet das zu erklärende Modell konsequent als Black-Box. Anstatt zu versuchen, die Entscheidungsfindung des Modells global abzubilden, approximiert LIME das Verhalten für eine spezifische Eingabe lokal durch ein einfaches, interpretierbares Ersatzmodell [11].

Formal unterscheidet LIME dazu zwischen der ursprünglichen Datenrepräsentation $x \in \mathbb{R}^d$ (beispielsweise den RGB-Pixelwerten eines Bildes) und einer interpretierbaren Repräsentation $x' \in \{0,1\}^{d'}$. Im Kontext der Bildklassifikation handelt es sich bei x' um einen binären Vektor, der die Präsenz (1) oder Absenz (0) von zusammenhängenden Bildbereichen – sogenannten Superpixeln – codiert.

Die Suche nach der optimalen lokalen Erklärung $\xi(x)$ wird als Optimierungsproblem definiert:

$$\xi(x) = \underset{g \in G}{\operatorname{argmin}} \mathcal{L}(f, g, \pi_x) + \Omega(g)$$

Formel 8: Allgemeine Optimierungsfunktion zur Bestimmung der Erklärung in LIME.
(Quelle: Ribeiro et al., 2016 [11])

Hierbei repräsentiert $g \in G$ das Ersatzmodell aus einer Klasse interpretierbarer Modelle G , wie etwa linearen Modellen. Der Term $\Omega(g)$ fungiert als Maß für die Komplexität des Modells (z. B. die Anzahl der Gewichte ungleich null), welches minimiert werden muss, um die menschliche Nachvollziehbarkeit zu gewährleisten. Das zugrunde liegende Black-Box-Modell wird als $f(x)$ beschrieben. Die Funktion $\pi_x(z)$ definiert als Distanzmaß die lokale Umgebung um das ursprüngliche Bild x . Die Verlustfunktion $\mathcal{L}(f, g, \pi_x)$ quantifiziert schließlich, wie stark das Ersatzmodell g in dieser durch π_x definierten Umgebung vom tatsächlichen Modell f abweicht.

Bei der Anwendung von LIME auf Bilddaten erfolgt die Erklärungsgenerierung in vier systematischen Schritten [11]:

1. **Segmentierung:** Einzelne Pixel sagen einem Menschen nichts. Deshalb unterteilt LIME das Bild zuerst in größere, zusammenhängende Abschnitte, sogenannte Superpixel [11]. Das sind Bereiche, die farblich oder von der Struktur her zusammengehören, wie beispielsweise ein bestimmter Fleck oder der gesunde Hautrand [11]. Sie bilden die Basis für die interpretierbaren Segmente x' .
2. **Perturbation (Störung):** Zur Analyse des lokalen Modellverhaltens wird ein Datensatz Z aus künstlich gestörten Samples generiert [11]. Dafür erzeugt LIME eine Vielzahl von Variationen $z' \in \{0,1\}^{d'}$, in denen zufällig ausgewählte Superpixel maskiert werden [11].
3. **Modell-Inferenz & Gewichtung:** Diese Binärvektoren z' werden in die ursprüngliche Repräsentation $z \in \mathbb{R}^d$ überführt (durch das Ausgrauen der entsprechenden Superpixel) und durch das Modell $f(z)$ klassifiziert [11]. Jede Variation erhält dabei ein Gewicht basierend auf der Distanzfunktion $\pi_x(z)$, wodurch dem Originalbild ähnliche Variationen stärker gewichtet werden [11].
4. **Training des Ersatzmodells:** Abschließend wird das interpretierbare Modell g auf dem so erstellten Datensatz Z optimiert. Für Bilddaten nutzt LIME in der Regel lineare Modelle der Form $g(z') = w_g * z'$. Als Verlustfunktion $\mathcal{L}$ dient dabei eine lokal gewichtete quadratische Abweichung:

$$\mathcal{L}(f, g, \pi_x) = \sum_{z, z' \in Z} \pi_x(z) (f(z) - g(z'))^2$$

Formel 9: Berechnung der Verlustfunktion mittels lokal gewichteter quadratischer Abweichung. (Quelle: Ribeiro et al., 2016 [11])




Abbildung 5: Schematische Funktionsweise von LIME. (Eigene Darstellung in Anlehnung an Ribeiro et al., 2016 [11])

Das Ergebnis ist eine Heatmap, die genau jene Superpixel hervorhebt, die das einfache Ersatzmodell als die wichtigsten Merkmale für die Vorhersage identifiziert hat. Im Gegensatz zur fließenden Heatmap von Grad-CAM liefert LIME somit eine klar abgegrenzte, abschnittsweise Darstellung der relevanten Hautbereiche [35].

Trotz seiner großen Flexibilität bringt LIME jedoch Herausforderungen mit sich, die im klinischen Alltag Probleme bereiten können. Da für die Annäherung im Hintergrund tausende Testdurchläufe durch das Modell nötig sind, ist LIME erheblich rechen- und zeitintensiv. Zudem zeigen Studien, dass LIME aufgrund des zufälligen Ausblendens von Bildteilen empfindlich auf minimales Bildrauschen reagiert. Das kann im schlimmsten Fall zu instabilen und widersprüchlichen Erklärungen führen [16].

2.3.3 Alternative XAI-Methoden

Neben Grad-CAM und LIME existiert in der aktuellen Forschung eine Vielzahl weiterer Post-hoc-Erklärbarkeitsmethoden. Da sich das Feld der Explainable AI dynamisch entwickelt, ist eine vollständige methodische Abdeckung im Rahmen einer Evaluierung kaum umsetzbar. Neben den bisher dargelegten Verfahren hat die XAI-Forschung diverse weitere Ansätze hervorgebracht, um Black-Box-Modelle transparent zu machen. Einen repräsentativen Überblick über den weiteren Stand der Technik liefern die folgenden Abschnitte, in denen die Grundlagen von SHAP, Integrated Gradients und SmoothGrad erläutert werden:

- **SHAP (SHapley Additive exPlanations):** SHAP ist ein theoretisch fundiertes Verfahren, das auf der kooperativen Spieltheorie aufbaut und jedem Eingabemerkmal einen exakten, fairen Beitrag zur finalen Modellvorhersage zuordnet [36]. Obwohl diese Zuteilung über Shapley-Werte mathematisch präzise ist, erfordert die exakte Berechnung die Evaluierung aller möglichen Merkmalskombinationen [36]. Dieser kombinatorische Aufwand macht das Verfahren sehr rechenintensiv.
- **Integrated Gradients (IG):** Ein weiterer gradientenbasierter Ansatz sind die Integrated Gradients (IG). Diese Methode ermittelt die Wichtigkeit der Bildmerkmale, indem sie die Gradienten entlang eines schrittweisen Übergangs zwischen einem neutralen Ausgangsbild (Baseline) und der finalen Eingabe aufsummiert. [37].
- **SmoothGrad:** SmoothGrad glättet Heatmaps optisch, indem es dem Eingabebild mehrfach künstliches Rauschen hinzufügt und den Durchschnitt der daraus resultierenden Gradienten bildet [38].

2.4 Evaluierungskriterien für XAI

Die Anwendung von XAI-Methoden wie Grad-CAM oder LIME erzeugt Heatmaps, die zeigen sollen, wie die Modelle zu ihrer Vorhersage kommen. Wenn Fachleute diese Erklärungen jedoch nur mit dem bloßen Auge beurteilen, ist das sehr subjektiv und anfällig für Fehler. Für die eigentliche Krankheitsdiagnose gibt es ein eindeutiges Richtig oder Falsch. Für die Erklärung des Modells existiert so ein klarer Maßstab jedoch nicht. Allein durch das Betrachten lässt sich nicht sicher feststellen, ob das Bild wirklich die echten Rechenwege des Modells zeigt oder ob es den Betrachter nur täuscht, weil die Markierungen zufällig medizinisch sinnvoll aussehen [6].

Um solche Erklärungen wissenschaftlich sauber zu beurteilen und verschiedene Methoden fair miteinander zu vergleichen, braucht es einheitliche Maßstäbe. In der Forschung und in medizinischen Richtlinien haben sich dafür feste Kriterien durchgesetzt, die für den Einsatz in der Medizin entscheidend sind. Das sind die Zuverlässigkeit der Erklärung, ihre Stabilität bei Bildfehlern sowie die Geschwindigkeit und die allgemeine Verständlichkeit für den Menschen [18].

2.4.1 Erklärungstreue (Faithfulness)

Die Erklärungstreue ist ein wichtigstes Qualitätsmerkmal eines XAI-Verfahrens. Sie misst, wie wahrheitsgemäß eine Heatmap den tatsächlichen internen Entscheidungsprozess des Modells widerspiegelt [39, 18]. Eine Methode mit hoher Erklärungstreue markiert genau die Bildbereiche als besonders wichtig, auf die sich das Modell auch bei seiner Klassifikation am stärksten gestützt hat.

Da sich die internen Entscheidungsprozesse des Modells nicht einfach ablesen lassen, wird die Erklärungstreue meist über gezielte Veränderungen am Bild gemessen. Die Logik dahinter ist: Wenn man die Bildbereiche löscht, die das XAI-Verfahren als wichtig eingestuft hat, muss die Sicherheit der Modellvorhersage für die jeweilige Klassifikation drastisch einbrechen [39]. Ändert sich die Vorhersagewahrscheinlichkeit nach dem Entfernen der markierten Stellen dagegen kaum, fehlt es der Methode an Erklärungstreue. In diesem Fall hat das Modell unwichtige Details fälschlicherweise als entscheidend dargestellt.

Zur quantitativen Messung der Erklärungstreue wird in dieser Arbeit das Prinzip der *Input Removal Of Features* (IROF) nach Rieger und Hansen (2020) [40] angewendet. Bei diesem Ansatz wird das Bild zuerst in eine feste Anzahl von Superpixeln (N) aufgeteilt. Diese Abschnitte werden anschließend anhand ihrer Wichtigkeit der Reihe nach sortiert, beginnend mit dem bedeutendsten Bereich. Die Metrik misst dann Schritt für Schritt, wie stark die Vorhersagewahrscheinlichkeit abfällt, während die wichtigsten Bildteile nacheinander ausgeblendet werden:

$$IROF(e_j) = \frac{1}{N} \sum_{n=1}^N AOC \left(\frac{F(X_n^l)_y}{F(X_n^0)_y} \right)_{l=0}^L$$

Formel 10: Mathematische Definition der IROF-Metrik (Iterative Removal of Features) zur quantitativen Berechnung der Erklärungstreue. (Quelle: Rieger & Hansen, 2020 [40])
(e_j = Erklärungsmethode)

Hierbei wird die Modellvorhersage nach dem Ausblenden von l Segmenten ($F(X_n^l)_y$) in ein direktes Verhältnis zur unmaskierten Basisvorhersage ($F(X_n^0)_y$) gesetzt. Der daraus resultierende Konfidenzverlust wird anschließend über die „Area Over the Curve“ (AOC) für alle Bildsegmente und Testbilder zu einem finalen Ergebnis für die Erklärungstreue aufsummiert.

Ein hoher IROF-Wert steht für eine hohe Erklärungstreue. Er zeigt an, dass das Modell seine Sicherheit schnell verliert, sobald man die vom XAI-Verfahren als wichtig markierten Bildbereiche entfernt.

2.4.2 Robustheit (Robustness)

Neben der Erklärungstreue ist die Robustheit der Erklärung von zentraler Bedeutung. Dieses Kriterium bewertet, wie stabil ein Verfahren bleibt, wenn das Eingabebild geringfügige, für das menschliche Auge kaum wahrnehmbare Veränderungen aufweist [16].

Die Kernanforderung lautet hierbei: Wenn zwei Bilder nahezu identisch sind und das Modell zu derselben Vorhersage kommt, dürfen die erzeugten Modellvorhersagen nicht stark voneinander abweichen [16]. Reagiert eine Methode zu empfindlich, liefert es bei minimalen Abweichungen des Bildes völlig unterschiedliche Darstellungen. Dies zerstört das Vertrauen in der Praxis, da man bei zwei fast identischen Bildern derselben Läsion widersprüchliche visuelle Hinweise erhalten würde. Um diese Beständigkeit zu überprüfen, wird gemessen, wie stark sich das Bild verändert, wenn das Ausgangsbild minimal abgewandelt wird [16].

In dieser Arbeit wird für diese Messung ausschließlich der sogenannte *Local Lipschitz Estimate* nach Alvarez-Melis und Jaakkola (2018) verwendet [16].

$$\widetilde{L}_X(x_i) = \operatorname{argmax}_{x_j \in N_\epsilon(x_i) \leq \epsilon} \frac{\|f(x_i) - f(x_j)\|_2}{\|x_i - x_j\|_2}$$

Formel 11: Mathematische Definition des Local Lipschitz Estimate zur Quantifizierung der lokalen Robustheit von XAI-Erklärungen. (Quelle: Alvarez-Melis & Jaakkola, 2018 [16])

Diese Metrik quantifiziert die Robustheit der Methode, indem sie deren Worst-Case-Szenario berechnet. Dafür sucht die Argmax-Funktion in der direkten Umgebung $N_\epsilon(x_i)$ nach genau demjenigen leicht gestörten Bild x_j , bei dem eine minimale optische Anpassung des Eingabebildes $(x_i - x_j)$ zur größtmöglichen Abweichung in der berechneten Heatmap $(f(x_i) - f(x_j))$ führt.

Ein niedriger Wert zeigt hierbei eine hohe Robustheit an, da die Modellvorhersagen trotz eines leichten Bildrauschens stabil bleiben.

2.4.3 Recheneffizienz und Verständlichkeit (Klinische Anwendbarkeit)

Das dritte zentrale Kriterium betrifft die praktische Einsetzbarkeit der Verfahren im medizinischen Alltag. Hierbei spielen zwei Faktoren eine wichtige Rolle: die benötigte Rechenzeit sowie die intuitive Verständlichkeit für den Anwender [18].

Einerseits darf die Wartezeit auf ein Ergebnis die täglichen Arbeitsabläufe nicht blockieren. Medizinische Entscheidungen sind oft zeitsensitiv, weshalb die Geschwindigkeit direkt am Behandlungsort eine Schlüsselrolle einnimmt [18]. Während gradientenbasierte Verfahren Erklärungen in der Regel sehr schnell berechnen können, erfordern perturbationsbasierte Methoden oftmals einen hohen zeitlichen Aufwand zur Generierung der visuellen Erklärungen [18]. Andererseits muss das Ergebnis so aufbereitet sein, dass es auch ohne tiefgehendes technisches Vorwissen über die genutzte Software verstanden werden kann [18]. Die Evaluation einer XAI-Methode für die dermatologische Praxis erfordert daher stets die Abwägung eines Kompromisses: Eine Methode muss eine ausreichend hohe diagnostische Qualität (Erklärungstreue und Robustheit) aufweisen, darf den Arzt jedoch weder durch unklare Visualisierungen verwirren noch durch unpraktikable Rechenzeiten behindern.

3. Datengrundlage und Modelltraining

Dieses Kapitel beschreibt die technische Vorbereitung der Bilddaten sowie den anschließenden Trainingsprozess der untersuchten Modellarchitekturen. Neben den Eigenschaften des HAM10000-Datensatzes werden die methodischen Schritte zur Bereinigung der Klassenimbalance sowie die Hyperparameter-Optimierung des Transfer Learnings für das ResNet-101 und MobileNetV3 definiert.

3.1 Der HAM10000 Datensatz

Als Datengrundlage für das Training und die anschließende Evaluation der Modelle in der vorliegenden Arbeit dient der HAM10000-Datensatz („Human Against Machine with 10000 training images“) [3]. Diese Bildsammlung wurde veröffentlicht, um das Problem zu lösen, dass es in der Dermatologie bislang kaum große, hochwertige und abwechslungsreiche Bilddatenbanken gab. In der heutigen Forschung gilt sie als fester Maßstab, um neue, automatische Diagnosesysteme zur Erkennung von Hautkrebs zu entwickeln und ihre Zuverlässigkeit miteinander zu vergleichen [3].

Die Sammlung beinhaltet insgesamt 10.015 Hautbilder, die über einen Zeitraum von 20 Jahren zusammengetragen wurden. Um eine große Vielfalt und eine hohe Praxisnähe zu garantieren, stammen die Bilder aus zwei völlig unterschiedlichen medizinischen Einrichtungen. Ein Teil wurde an der Universitätsklinik für Dermatologie der Medizinischen Universität Wien in Österreich aufgenommen, der andere Teil stammt aus einer spezialisierten Hautkrebspraxis in Queensland in Australien [3]. Ein wesentliches Qualitätsmerkmal dieser Bildsammlung ist die hohe Zuverlässigkeit der hinterlegten Diagnosen, also der tatsächlichen Wahrheit. Bei mehr als der Hälfte aller abgebildeten Hautläsionen wurde die Diagnose durch eine feingewebliche Untersuchung im Labor zweifelsfrei bewiesen. Die restlichen Fälle wurden entweder durch spätere ärztliche Nachkontrollen, das übereinstimmende Urteil mehrerer Fachleute oder mithilfe einer speziellen Lasermikroskopie abgesichert [3]. Diese Kombination verschiedener Prüfverfahren garantiert eine äußerst verlässliche Datenbasis für das überwachte Modelltraining (Supervised Learning).

Der HAM10000-Datensatz bildet die medizinische Praxis sehr gut ab, da er über 95% der gängigen pigmentierten Hautläsionen umfasst. Die Bilder sind in sieben diagnostische Hauptkategorien unterteilt [4], 3]:

KÜRZEL	ENGLISCHE BEZEICHNUNG	DEUTSCHE BEZEICHNUNG	ANZAHL BILDER
(a) nv	Melanocytic nevi	Gutartige melanozytäre Nävi (klassische Muttermale)	6.705
(b) mel	Melanoma	Malignes Melanom (schwarzer Hautkrebs)	1.113
(c) bkl	Benign keratosis-like lesions	Gutartige keratotische Läsionen (z. B. seborrhoische Keratosen)	1.099
(d) bcc	Basal cell carcinoma	Basalzellkarzinom (weißer Hautkrebs)	514
(e) akiec	Actinic keratoses	Aktinische Keratosen und intraepitheliale Karzinome (Frühformen des Plattenepithelkarzinoms)	327
(f) vasc	Vascular lesions	Vaskuläre Läsionen (z. B. Angiome)	142
(g) df	Dermatofibroma	Dermatofibrome (gutartige Bindegewebstumore)	115

Tabelle 1: Übersicht und Verteilung der sieben Hautläsionsklassen im HAM10000-Datensatz [3].




Abbildung 6: Repräsentative dermatoskopische Aufnahmen aus dem HAM10000-Datensatz.

Ein typisches und für das maschinelle Lernen problematisches Merkmal des HAM10000-Datensatzes ist seine starke Klassenimbalance [42, 41]. Diese ungleiche Verteilung spiegelt die tatsächliche Häufigkeit von Krankheiten im medizinischen Alltag wider, in dem gutartige Muttermale weitaus öfter diagnostiziert werden als bösartige Tumore. Die Gruppe der gewöhnlichen Muttermale (nv) dominiert den Datensatz mit über 67%, während seltene Kategorien wie Dermatofibrome (df) stark unterrepräsentiert sind.




Abbildung 7: Verteilung der sieben Hautläsionsklassen im HAM10000-Datensatz.

Wird ein CNN auf diesen Daten trainiert, besteht das Risiko, dass das Modell einen Bias zugunsten der Mehrheitsklasse entwickelt [43]. Das Modell könnte eine hohe Gesamtgenauigkeit erzielen, indem es nahezu jede Läsion als gutartig klassifiziert, was im medizinischen Kontext – insbesondere bei der Übersehung eines Melanoms – zu klinisch relevanten Fehldiagnosen führen könnte.

Darüber hinaus unterscheiden sich die Bilder des HAM10000-Datensatzes teilweise bei der Beleuchtung, dem gewählten Bildausschnitt und der Auflösung. Besonders wichtig für die Erklärbarkeitsanalyse in dieser Arbeit ist außerdem, dass die Bilder Störfaktoren wie Haare, Markierungen oder sichtbare Lineale enthalten. Solche Bildelemente bergen das Risiko eines sogenannten „Clever Hans“-Effekts [12] (vgl. Kapitel 6.3). Dabei lernt das Modell nicht die echten Merkmale der Hautveränderung, sondern stützt seine Entscheidung fälschlicherweise auf irrelevante Bildmerkmale. Um dieses Ungleichgewicht und die damit verbundenen Risiken methodisch auszugleichen, werden die Bilddaten vor dem Modelltraining vorverarbeitet.

3.2 Datenvorbereitung, Augmentierung und Splitting

Die Vorbereitung der Bilddaten ist ein essenzieller Schritt bei der Entwicklung von Deep-Learning-Modellen [15]. Um die im vorangegangenen Kapitel beschriebenen Herausforderungen des HAM10000-Datensatzes zu lösen, erfordern die Bilder eine systematische Aufbereitung [30]. Dieses Kapitel beschreibt den dafür notwendigen mehrstufigen Prozess: Nach der strikten Aufteilung der Daten und der technischen Skalierung der Bilder wird erläutert, wie das Ungleichgewicht der Läsionsklassen durch gezieltes Oversampling ausgeglichen und die Trainingsbilder abschließend durch Datenaugmentierung künstlich erweitert wird.

3.2.1 Datensplit und Stratified Sampling

Um eine methodisch saubere Evaluation der Modelle und der späteren XAI-Methoden zu gewährleisten, muss der Datensatz strikt in Trainings-, Validierungs- und Testdaten unterteilt werden [23]. In Anlehnung an Sangwan et al. (2024) [15] wurde zunächst ein separater Testdatensatz von 15 % (ca. 1.500 Bilder) abgespalten. Diese ungesesehenen Bilder wurden während des gesamten Trainingsprozesses nicht verwendet und dienen am Ende zur Prüfung der Generalisierungsfähigkeit der Modelle sowie als Basis für die Extraktion der True-Positive-Bilder für die XAI-Evaluation.

Die bewusste Beschränkung der quantitativen XAI-Evaluation auf korrekt klassifizierte Bilder (True Positives) ist methodisch zwingend erforderlich, um die Fehlerhaftigkeit des CNN von der Fehlerhaftigkeit der XAI-Methode zu trennen [14]. Trifft ein Modell eine inkorrekte Vorhersage (False Positive oder False Negative), ist es mathematisch unmöglich zu trennen, ob eine fehlerhafte Heatmap durch das Versagen der Erklärungsmethode oder durch unsinnig erlernte Merkmale des Modells verursacht wurde [14]. Aus diesem Grund werden Fehlklassifikationen von der quantitativen Berechnung ausgeschlossen und erst im späteren Verlauf der Arbeit im Rahmen einer qualitativen Analyse (vgl. Kapitel 5.5) gesondert untersucht.

Die verbleibenden 85 % der Daten wurden in einem 75-25-Split [15] aufgeteilt, sodass bezogen auf den Gesamtdatensatz 63,75 % auf das Training und 21,25 % auf die Validierung entfallen [15]. Um sicherzustellen, dass die Verteilung der sieben Hautläsionsklassen in allen drei Subdatensätzen repräsentativ bleibt, wurde *Stratified Sampling* angewendet [41]. Dies garantiert, dass selbst seltene Läsionen in den Trainings- und Testphasen in proportional korrekter Menge vorhanden sind [44].

Um sicherzustellen, dass die zufällige Aufteilung der Bilder in die jeweiligen Subdatensätze bei jedem Programmdurchlauf exakt gleich bleibt, wurde der Datensplit mit einem fest definierten Random-Seed fixiert. Dies garantiert eine unveränderliche Datenbasis für das gesamte Modelltraining und alle nachfolgenden XAI-Experimente.

3.2.2 Methodischer Umgang mit der Klassenimbalance

Um das Ungleichgewicht aus Kapitel 3.1 methodisch zu lösen, wurde ein gezieltes Oversampling der Daten eingesetzt. Ein Training mit den unveränderten Bildern würde sonst dazu führen, dass das Modell die häufigste Klasse bevorzugt und die Erkennung der selteneren, medizinisch aber wichtigen Krankheiten deutlich verschlechtert. Um dieses Problem zu lösen, werden Kopien von Bildern aus den selteneren Klassen erstellt, wodurch das Modell eine deutlich ausgewogenere Datenbasis erhält [15]. Ein vollständiges Angleichen seltener Fälle an die größte Gruppe birgt jedoch ein hohes Risiko für Overfitting. Da exakt dieselben Bilder in jedem Trainingsdurchlauf dutzendfach in das Modell eingespeist würden, lernt das Modell die Trainingsbilder lediglich auswendig, anstatt allgemeingültige Muster zu erkennen [45].

In Anlehnung an Sangwan (2024) [15] wurde für das Oversampling in dieser Arbeit daher eine Obergrenze von maximal 300 % Wachstum (entspricht einer Vervierfachung) für kleinere Klassen angestrebt. Diese Regel stellt einen Kompromiss dar, um Minderheitsklassen zu stärken, ohne die Generalisierungsfähigkeit durch Duplikate zu gefährden.

Um zu verhindern, dass identische Bildkopien durch den Split sowohl im Trainings- als auch im Testdatensatz landen, darf das Oversampling erst nach der Datentrennung und ausschließlich auf dem reinen Trainingsset durchgeführt werden. Andernfalls würde das Modell im Test ungesehene Daten vortäuschen, die es im Training bereits exakt so gelernt hat. Dafür wurde in dieser Arbeit eine dynamische Oversampling-Strategie implementiert. Diese berechnet die Zielgrößen für das Kopieren, passend zur tatsächlichen Verteilung, innerhalb des Trainingssets. Jede Minderheitsklasse wird dabei um maximal 300 % im Verhältnis zu ihrer aktuellen Häufigkeit vergrößert, wobei die resultierende Bildanzahl durch die absolute Größe der Mehrheitsklasse im Trainingsset begrenzt wird. Diese dynamische Anpassung stellt ein balanciertes Training sicher und garantiert gleichzeitig die Unabhängigkeit der Evaluationsdaten.

Wie Abbildung 8 veranschaulicht, führt diese Strategie zu einer signifikanten Angleichung der Klassenhäufigkeiten im Trainingsdatensatz, wodurch verhindert wird, dass das Modell während der Trainingsphase einen starken Bias zugunsten der melanozytären Nävi (nv) entwickelt.




Abbildung 8: Gegenüberstellung der Klassenverteilung im Trainingsdatensatz vor und nach dem dynamischen Oversampling.

Durch das reine Kopieren der Bilder beim Oversampling besteht jedoch die Gefahr, dass das Modell diese Duplikate einfach nur auswendig lernt. Um dies zu verhindern, werden die Bilder durch eine dynamische Augmentierung optisch variiert (vgl. Kapitel 3.2.4).

3.2.3 Bildskalierung und Normalisierung

Da tiefe neuronale Netzwerke, wie die hier verwendeten Architekturen ResNet-101 und MobileNetV3, standardisierte Bildformate benötigen, müssen die Bilder vorverarbeitet werden. Die Bilder wurden auf eine einheitliche Auflösung von 224x224 Pixeln skaliert, um während des Modelltrainings Einheitlichkeit zu gewährleisten [4, 46]. Diese spezifische Größe hat sich in der medizinischen Bildverarbeitung als optimaler Standard etabliert, um hardwareseitige Limitierungen des GPU-Arbeitsspeichers zu umgehen und ein recheneffizientes Training zu ermöglichen [4]. Zusätzlich wurden die Pixelwerte der Bilder normalisiert. Hierbei wurde ein Rescaling durchgeführt, bei dem alle RGB-Pixelwerte (die ursprünglich zwischen 0 und 255 liegen) durch 255 dividiert werden, um sie in einen einheitlichen Wertebereich (0-1) zu überführen [42]. Da die verwendeten Netzwerke jedoch mittels Transfer Learning vortrainiert wurden, ist ein weiterer Anpassungsschritt zwingend erforderlich: Die Daten wurden mit den spezifischen Mittelwerten und Standardabweichungen des *ImageNet*-Datensatzes normalisiert (offizieller Standard des PyTorch-Frameworks für ImageNet-Transfer-Learning). Diese Normalisierung beschleunigt die Konvergenzrate während des Trainings erheblich und ist eine Grundvoraussetzung für Modelle, die mittels Transfer Learning vortrainiert wurden [23]. Da diese Modelle bereits darauf trainiert sind, mit sehr kleinen Zahlenwerten zu rechnen, würden normal große Bildwerte den Lernprozess stören und das bereits erlernte Vorwissen der Modelle direkt überschreiben.

Um Speicherplatz zu sparen, erfolgte diese Vorverarbeitung nicht als vorgelagerter Schritt. Stattdessen wurde die Skalierung sowie die anschließende Normalisierung als zusammenhängende Pipeline dynamisch zur Laufzeit beim Laden der jeweiligen Bild-Batches angewendet [15]. Bei den Trainingsdaten griffen diese Schritte dabei nahtlos in die zufälligen Datenaugmentierungen (vgl. Kapitel 3.2.4) ein, welche für jede Epoche neu berechnet wurden.

3.2.4 Datenaugmentierung

Um dem Overfitting entgegenzuwirken, wurde der Trainingsdatensatz durch Datenaugmentierung künstlich erweitert [47]. Dies ist in der medizinischen Diagnostik ein kritischer Faktor, da Modelle zuverlässig auf völlig neue Patientendaten reagieren müssen. Da medizinische Datensätze in ihrer Größe oft stark limitiert sind, wirkt die Augmentierung dem Overfitting entgegen. Sie minimiert das Risiko von Overfitting, indem sie dem Training absichtlich kleine Veränderungen hinzufügt [23]. Diese Variation der Trainingsdaten reduziert das Overfitting-Risiko und sorgt dafür, dass das Modell gelernte Muster wesentlich besser auf neue, ungesehene Bilder übertragen kann. [47].

Dabei wurden geometrische und optische Veränderungen zufällig und dynamisch während des laufenden Trainingsprozesses auf die Bilder angewendet [15]. Zu den in dieser Arbeit genutzten Techniken gehören:

- **Geometrische Transformationen:** Zufällige Rotationen, horizontale sowie vertikale Spiegelungen (Flips), Scherungen (Shears) und Zoom-Verschiebungen [42, 44].
- **Optische Transformationen:** Zufällige Anpassungen der Helligkeit (Brightness Shifts) und Farbkanalverschiebungen (Channel Shifts) [15].




Abbildung 9: Exemplarische Auswirkungen der Datenaugmentierung auf ein dermatoskopisches Bild des HAM10000-Datensatzes.

Durch diese Methodik wird die effektive Größe des Trainingsdatensatzes enorm erhöht [46, 47]. Da in jedem Trainingsdurchlauf eine neue, zufällige Augmentierung auf jedes Bild angewendet wird, erhält das Modell fortlaufend leicht abweichende Informationen. Dadurch wird es mit einer wesentlich größeren Vielfalt an möglichen Bedingungen konfrontiert [15]. Dies zwingt das CNN dazu, abstrakte, positions- und rotationsunabhängige Merkmale der Hautläsionen zu erlernen, was die Robustheit des Modells gegenüber den typischen Schwankungen in realen dermatoskopischen Bildern deutlich erhöht [23, 47].

3.3 Hyperparameter und Modelloptimierung

Die Leistungsfähigkeit neuronaler Netzwerke hängt neben der Architektur und der Datenqualität maßgeblich von der Wahl der Hyperparameter ab [48]. Hyperparameter definieren die Rahmenbedingungen des Trainingsprozesses und müssen sorgfältig abgestimmt werden, um zu gewährleisten, dass das Modell komplexe Merkmale der Hautläsionen erlernt, ohne die Trainingsdaten lediglich auswendig zu lernen [23]. Um eine optimale Generalisierungsfähigkeit der Modelle auf dem HAM10000-Datensatz [3] zu erreichen, stützt sich die Optimierungsstrategie dieser Arbeit auf etablierte Best Practices der medizinischen Bildklassifikation [46, 15].

3.3.1 Verlustfunktion und Optimierungsalgorithmus

Für das Training der Netzwerke wurde die *Categorical Cross-Entropy* als Verlustfunktion verwendet. Laut Goodfellow et al. (2016) [23] kommt bei binären Klassifikationen unter der Annahme einer Bernoulli-Verteilung standardmäßig die reguläre *Cross-Entropy* zum Einsatz. Da es sich in dieser Arbeit jedoch um ein Multiklassenproblem mit sieben Hautläsionsklassen handelt, wurde stattdessen die kategoriale Variante *Categorical Cross-Entropy* benötigt.

$$Loss = - \sum_{i=1}^K y_i * \log(\hat{y}_i)$$

Formel 12: Categorical Cross-Entropy: Dabei ist K die Anzahl der Klassen, y ist der wahre Wert und $\hat{y}$ ist die vom Modell vorhergesagte Wahrscheinlichkeit für die Klasse k .

Da sich die Klassen gegenseitig ausschließen, harmonisiert dieses Verfahren ideal mit der *Softmax*-Aktivierung der letzten Netzwerkschicht [23]. Der entscheidende Vorteil im medizinischen Kontext liegt dabei in der logarithmischen Fehlerberechnung: Durch die logarithmische Berechnung wächst der Loss-Wert stark an, sobald das Modell einer falschen Klassifikation eine sehr hohe Wahrscheinlichkeit zuordnet. Dies führt dazu, dass das Netzwerk seine Gewichte realistischer anpasst [15].

Um die Gewichte des Netzwerks zur Minimierung dieser Loss-Werte anzupassen, wurde der *Adam*-Optimierer (Adaptive Moment Estimation) eingesetzt [49]. *Adam* kombiniert die Vorteile adaptiver Lernraten mit der Berücksichtigung historischer Gradienten. In der Praxis der Klassifikation von Hautläsionen hat sich gezeigt, dass *Adam* im Vergleich zum traditionellen stochastischen Gradientenabstieg (SGD) eine wesentlich schnellere und stabilere Konvergenz der Modelle ermöglicht [15]. Während der Optimierer die Richtung der Gewichtsadjustierungen vorgibt, regelt die Lernrate im weiteren Verlauf die exakte Schrittweite.

$$\Theta_{t+1} = \Theta_t - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t$$

Formel 13: Parameter-Aktualisierung des Adam-Optimierers. Dabei ist Θ die Netzwerkgewichte, η die Basis-Lernrate, $\hat{m}_t$ der gleitende Mittelwert der Gradienten (Momentum), $\hat{v}_t$ die Adaptive Schrittweiten-Skalierung und ϵ ein numerischer Stabilisator.

3.3.2 Steuerung der Lernrate (Learning Rate Scheduling)

Die initiale Lernrate gilt als einer der kritischsten Hyperparameter beim Training von Deep-Learning-Modellen [48]. Um eine feingranulare Anpassung der Netzwerkgewichte im späteren Trainingsverlauf zu ermöglichen, wurde ein dynamischer Lernraten-Scheduler (*ReduceLROnPlateau*) implementiert [15].

Dieser überwachte kontinuierlich den Validierungsfehler. Sobald die Leistung des Netzwerks über eine definierte Anzahl von zwei Epochen hinweg stagniert (*Patience*), wird die Lernrate automatisch um einen sanften Faktor von 0,5 reduziert. Dieser Reduktionsfaktor hat sich in der Literatur gegenüber härteren Abstufungen für die Klassifikation von Hautläsionen bewährt, da er es dem Netzwerk erlaubt, sich dem globalen Minimum schrittweise anzunähern, lange bevor das reguläre Early Stopping (vgl. Kapitel 3.3.3) den Trainingsprozess abbricht [46]. Diese sanfte Reduktion ist besonders in der Phase des Fine-Tunings (vgl. Kapitel 3.4) essenziell, um die Netzwerkgewichte durch minimale Schritte exakt zu justieren und ein Überspringen des Minimums zu verhindern [44].

3.3.3 Batch-Size, Dropout und Early Stopping

Die *Batch-Size* definiert, wie viele Bilder gleichzeitig durch das Netzwerk propagiert werden, bevor ein Gewichtsupdate stattfindet. In Anlehnung an vergleichbare Studien zur medizinischen Bildanalyse wurde eine Batch-Größe von 32 Bildern gewählt, was empirisch einen idealen Kompromiss zwischen GPU-Speicherauslastung, Trainingsstabilität und Konvergenzgeschwindigkeit bietet [46].

Das größte Risiko beim Training auf begrenzten medizinischen Datensätzen ist das *Overfitting* [23]. Um dies zu verhindern, wurde ein *Dropout* vor der finalen Klassifikationsschicht angewendet, welcher zufällig Neuronen deaktiviert und das Netzwerk zwingt, robustere Merkmale zu erlernen [50].

Da sich die beiden Architekturen in ihrer Parameteranzahl jedoch deutlich unterscheiden, erfordern sie unterschiedliche *Dropout*-Werte: Für das tiefe und parameterreiche ResNet-101 wurde ein hoher *Dropout*-Wert von 0,5 gewählt, um einem starken Overfitting zuverlässig entgegenzuwirken [15, 46]. Das leichtgewichtige MobileNetV3 [26] hingegen würde bei einer derart starken Regularisierung an Repräsentationskraft verlieren; es wurde daher mit einem reduzierten *Dropout*-Wert von 0,3 trainiert, was den Best Practices für diese spezifische Architektur bei der Klassifikation von Hautläsionen entspricht [46].

Zusätzlich wurde bei beiden Modellen das Konzept des *Early Stopping* angewendet [23]. Verbessert sich der Validierungsfehler über eine definierte Anzahl von 10 Epochen nicht weiter, wurde das Training automatisch abgebrochen. Das Modell wurde in diesem Fall auf den Zustand (die Epoche) mit dem geringsten Fehler zurückgesetzt, um die maximale Generalisierungsfähigkeit für die nachfolgende XAI-Evaluation zu bewahren. Diese Sicherheitsmechanismen greifen während des gesamten Lernprozesses, welcher sich strategisch in zwei aufeinander aufbauende Phasen unterteilt (vgl. Kapitel 3.4).

3.4 Durchführung des Transfer Learnings

Aufbauend auf den theoretischen Grundlagen (vgl. Kapitel 2.2) wurde für das Training der Modelle auf den HAM10000-Datensatz auf das Prinzip des Transfer Learning zurückgegriffen [31]. Dabei wurden die Modelle mit vortrainierten Gewichten aus dem ImageNet-Datensatz initialisiert, um generische visuelle Merkmale wie Kanten und Kontraste zu nutzen [33]. Um das Netzwerk optimal an den HAM10000-Datensatz anzupassen, ohne dieses wertvolle Vorwissen zu zerstören, erfolgte das Training in einem zweistufigen Optimierungsprozess [43, 15]:

- **Phase 1 (Warm-up der Klassifikationsschicht):** Im ersten Schritt wurden die ursprünglichen Top-Schichten der Modelle durch neue, vollständig vernetzte Schichten (Fully-Connected Layers) ersetzt, die als Klassifikator für die sieben Hautläsionsklassen konfiguriert sind [15]. Da die Gewichte dieser neuen Schichten zu Beginn rein zufällig initialisiert sind, wäre der anfängliche Fehler hoch [48]. Würde das gesamte Netzwerk sofort trainiert werden, würden die daraus resultierenden Fehlergradienten das fein abgestimmte Vorwissen der tieferen Schichten sofort überschreiben und zerstören [48]. Daher wurden zunächst alle Basis-Schichten des Netzwerks "eingefroren", sodass ihre Parameter für das Gradienten-Update gesperrt sind [44].
- **Phase 2 (Fine-Tuning des Netzwerks):** Nachdem der Klassifikator-Kopf erfolgreich vortrainiert wurde, wurden die tieferen Schichten des Netzwerks wieder "aufgetaut", um eine domänenspezifische Merkmalsextraktion für die Bilder zu ermöglichen [15]. In dieser zweiten Phase wurden die Schichten gemeinsam weitertrainiert [44]. Hierbei war es essenziell, die Lernrate auf einen sehr kleinen Wert (z. B. 0,0001) zu reduzieren [48]. Durch die kleine Lernrate wurde sichergestellt, dass die tieferen Faltungsschichten sanft und präzise an die spezifischen Texturen und Muster der Hautläsionen feinangepasst (Fine-Tuning) werden [43, 41].

4. Methodik und experimenteller Ablauf

Nachdem die Modelle im vorangegangenen Kapitel erfolgreich für die dermatologische Klassifikationsaufgabe trainiert und optimiert wurden, beschreibt dieses Kapitel die methodische Umsetzung der Evaluation. Um die Black-Box-Entscheidungen der Modelle zu validieren, verfolgt diese Arbeit ein streng kontrollierten, experimentellen Ablauf, welcher die Leistungsfähigkeit und Verlässlichkeit der unterschiedlichen XAI-Methoden systematisch und quantitativ messbar macht. Im Folgenden wird zunächst die Auswahl der zu evaluierenden XAI-Methoden begründet, bevor der experimentelle Ablauf zur Modellvorhersage, zur Erklärungsgenerierung und schließlich zur standardisierten quantitativen Evaluation im Detail vorgestellt wird.

4.1 Begründung der XAI-Methodenauswahl

Wie in den theoretischen Grundlagen (vgl. Kapitel 2.3.1 und 2.3.2) beschrieben, funktionieren Grad-CAM [10] und LIME [11] grundlegend verschieden. Genau dieser starke Gegensatz ist der Hauptgrund für ihre Auswahl in dieser Arbeit. Anstatt ähnliche Methoden zu vergleichen, stehen sich hier die beiden wichtigsten Grundkonzepte direkt gegenüber. Durch diesen bewussten Kontrast lässt sich unter exakt gleichen Bedingungen messen, wie sich die unterschiedlichen Konzepte auf die Robustheit und die Erklärungstreue auswirkt.

Gegenüber vergleichbaren gradientenbasierten Ansätzen erweist sich Grad-CAM [10] für als besonders geeignet. Da es im Gegensatz zu den *Integrated Gradients* ohne ein künstliches Referenzbild auskommt, bietet es für komplexe medizinische Bilddaten eine theoretisch robustere Ausgangsbasis [10, 37]. Auch gegenüber *SmoothGrad* bietet Grad-CAM entscheidende Vorteile für die vorliegende Evaluierung [10, 38]. Da sich die Diagnostik maßgeblich auf feinste Bilddetails stützt, eignet sich der unverfälschte Gradientenfluss von Grad-CAM besser, als durch künstliches Rauschen potenziell krankheitsentscheidende Merkmale zu verzerren [38].

Gegenüber vergleichbaren perturbationsbasierten Ansätzen – insbesondere SHAP – erweist sich LIME für diese Evaluierung als besonders geeignet, da es einen konzeptionell ressourcenschonenderen Ansatz verfolgt [36]. Weil es lediglich lokale Ersatzmodelle trainiert, anstatt globale Spieltheorie-Werte zu berechnen, umgeht LIME die hohen Rechenzeiten, die den schnellen Einsatz von SHAP in einem klinischen Point-of-Care-Szenario ausschließen würden [11, 36].

Die bewusste methodische Beschränkung auf diese beiden Methoden – anstelle eines breiten Vergleichs der unzähligen verfügbaren XAI-Methoden im medizinischen Bereich [18, 9] – resultiert aus den erheblichen Hardware- und Zeitressourcen, die für die Berechnung der Evaluierungsmetriken erforderlich sind. Dieser fokussierte Rahmen ermöglicht es, trotz der von Rieger und Hansen (2020) [40] beschriebenen rechnerischen Hindernisse, einen detaillierten Vergleich der beiden gegensätzlichen Methoden Grad-CAM und LIME durchzuführen. Dieser kontrollierte Ansatz verlangt jedoch auch eine strikte technische Standardisierung, weshalb die gesamte Untersuchung auf der nachfolgend beschriebenen Software-Infrastruktur aufbaut.

4.2 Software-Infrastruktur und Evaluierungsframework

Um eine hohe wissenschaftliche Reproduzierbarkeit und Standardisierung der Experimente zu gewährleisten, stützt sich das gesamte methodische Setup dieser Arbeit auf etablierte Open-Source-Frameworks. Die Architektur der Evaluierungspipeline lässt sich in drei funktionale Bereiche unterteilen: die Deep-Learning-Basis, die Frameworks zur XAI-Generierung sowie das Toolkit zur quantitativen Evaluation.

4.2.1 Deep-Learning-Basis

Als zentrales Framework für das Training der CNNs sowie für die anschließende Klassifikation kam *PyTorch* zum Einsatz [51]. *PyTorch* hat sich aufgrund seiner imperativen Programmierweise und der nativen Hardwarebeschleunigung als Standard für Deep-Learning-Anwendungen etabliert [51].

Auf die Nutzung des ebenfalls populären Frameworks TensorFlow [52], welches in vergleichbaren Studien wie der von Sangwan (2024) [15] zum Einsatz kam, wurde in dieser Arbeit bewusst verzichtet. Der Hauptgrund dafür ist die reibungslose Einbindung der XAI-Infrastruktur.

4.2.2 Frameworks zur XAI-Generierung

Zur Generierung der Heatmaps für die klassifizierten Testbilder wurden zwei spezialisierte Bibliotheken eingesetzt, um Fehler durch ungenaue Eigenimplementierungen der komplexen Algorithmen auszuschließen.

Zur Berechnung des Grad-CAM-Verfahrens wurde die Bibliothek *Captum* genutzt, welche für *PyTorch* entwickelt wurde [53]. Diese stellt den benötigten Algorithmus nativ für die verwendeten Netzwerkarchitekturen bereit [53].

Für den modellagnostischen Ansatz wurde das originale *LIME*-Paket in die Pipeline integriert [11]. Dieses Paket übernimmt automatisiert die methodisch anspruchsvolle Segmentierung der Eingabebilder in Superpixel sowie die Störung (Perturbation) und das anschließende Training der lokalen Ersatzmodelle [11].

4.2.3 Quantitative Evaluation: Das Quantus-Framework

Den methodischen Kern der Evaluation bildet das *Quantus*-Framework [54]. In der bisherigen XAI-Forschung mangelt es oft an methodischer Standardisierung; Evaluierungsmetriken werden häufig mit unterschiedlichen Parametrisierungen selbst implementiert oder Erklärungen werden lediglich durch menschliche, visuelle Einschätzungen qualitativ und damit subjektiv bewertet [54].

Quantus löst dieses Problem als dediziertes, quelloffenes Python-Toolkit zur Validierung von Erklärungsmethoden [54]. Der Einsatz von *Quantus* ersetzt die fehleranfällige, bloße Begutachtung mit dem Auge durch klare mathematische Regeln. Dadurch lässt sich die Erklärungsqualität von Grad-CAM und LIME objektiv und standardisiert messen.

4.2.4 Hardware-Infrastruktur

Damit die Latenzzeiten (Δt) der XAI-Methoden aus Kapitel 5.4 fair und reproduzierbar bewertet werden konnten, fanden sämtliche Experimente auf einer einheitlichen Hardware-Infrastruktur statt. Um die Modell-Inferenzen, Perturbationen und Quantus-Metriken effizient zu verarbeiten, wurde durchgehend eine GPU-Beschleunigung via CUDA genutzt. Die genauen Spezifikationen des Testsystems sind in Tabelle 2 aufgeführt.

KOMPONENTEN	SPEZIFIKATION
Prozessor (CPU)	12th Gen Intel® Core(TM) i5-1250
Grafikkarte (GPU)	NVIDIA GeForce GTX 1660 TI, 6 GB GDDR6-VRAM
Arbeitsspeicher (RAM)	40 GB DDR4-3200 MHz
CUDA-Framework	CUDA Version 13.1
Betriebssystem	Microsoft Windows 11 Pro

Tabelle 2: Spezifikation der genutzten Hardware-Infrastruktur.

4.3 Experimenteller Ablauf: Modellvorhersage und Erklärungsgenerierung

Nachdem die strukturellen Rahmenbedingungen der Pipeline definiert wurden, beschreibt dieses Kapitel die konkrete Ausführung der Experimente. Dies umfasst den Evaluationsprozess auf den ungesehenen Testdaten sowie die exakten Mechanismen, mit denen die beiden XAI-Methoden ihre visuellen Erklärungen für die Black-Box-Entscheidungen der Modelle generieren.

4.3.1 Bestimmung der Modell-Performance und XAI-Testdatenaufteilung

Zur Vorbereitung der Erklärungsgenerierung wurden die gelernten Gewichte der beiden CNNs fixiert und die Netzwerke in den Inferenzmodus versetzt. Dies sichert eine deterministische Vorhersage über den gesamten Testverlauf.

Im ersten Schritt verarbeiteten beide Modelle den vollständigen, ungesehenen Testdatensatz. Die daraus resultierende Ermittlung der Klassifikationsgüte – also von Konfusionsmatrizen, Präzision, Recall und F2-Scores – ist an dieser Stelle aus zwei Gründen von zentraler Bedeutung: Einerseits liefert sie den Nachweis, dass die Modelle verlässlich arbeiten und stabile Merkmalsrepräsentationen erlernt haben, was die zwingende Voraussetzung für eine wissenschaftlich fundierte XAI-Analyse darstellt. Andererseits liefern diese Leistungsdaten die quantitative Baseline für den späteren Vergleich in der Diskussion. Sobald diese Gesamtleistung bestimmt war, erfolgte die gezielte Datenfilterung für die eigentliche XAI-Evaluation. Um Modell- und Erklärungsfehler sauber voneinander zu trennen, wurde die Stichprobe für die Durchläufe im *Quantus*-Framework auf die korrekt klassifizierten True-Positive-Bilder beschränkt (vgl. Kapitel 3.2.1).

4.3.2 Erklärungsgenerierung mittels Grad-CAM

Zur Erstellung der Grad-CAM-Erklärungen wurde das Framework *Captum* eingesetzt. Dafür verarbeiteten die beiden Modelle, ResNet-101 und MobileNetV3, die zuvor gefilterten True-Positive-Bilder. *Captum* griff bei der Berechnung einheitlich auf die letzte Faltungsschicht der Netzwerke zu (vgl. Kapitel 2.3.1). Die daraus resultierenden Relevanzwerte wurden anschließend auf einen Bereich zwischen 0 und 1 normalisiert und exakt auf die Originalbildgröße von 224x224 Pixeln hochskaliert. Diese fertigen Heatmaps bilden dann die direkte Datengrundlage für die spätere Auswertung im *Quantus*-Framework.

4.3.3 Erklärungsgenerierung mittels LIME

Die Erklärungsgenerierung mittels LIME erfolgte unter Einsatz der offiziellen LIME-Bibliothek [11]. Das ResNet-101 und das MobileNetV3 wurden der Methode hierbei ausschließlich als Black-Boxen übergeben (vgl. Kapitel 2.3.2). Für die Verarbeitung der True-Positive-Bilder wurde das Bild zunächst durch den SLIC-Algorithmus in semantische Superpixel segmentiert. Im anschließenden Perturbationsschritt generierte LIME die gestörten Bildvariationen durch das Maskieren von Superpixel. Um den Kompromiss zwischen Erklärungsqualität und Rechenaufwand im weiteren Verlauf zu evaluieren, wurde die Anzahl der generierten Störungen (Samples N) in den einzelnen Testzyklen (vgl. Tabelle 3) variiert. Die auf diese Weise erzeugten Heatmaps bilden ebenfalls die Datengrundlage für die spätere Auswertung im Quantus-Framework.

4.3.4 Experimentelles Design und Parameter-Variation

Da perturbationsbasierte XAI-Methoden wie LIME mit einem hohen Rechenaufwand verbunden sind, ist die Wahl der Hyperparameter entscheidend für die klinische Praxistauglichkeit. Wie Sangwan (2024) [15] aufzeigt, hat die Parametrisierung von Erklärungsalgorithmen direkten Einfluss auf die gemessene Qualität der Erklärungen hinsichtlich ihrer Erklärungstreue und Robustheit. Um für den klinischen Einsatz den besten Kompromiss aus hoher Erklärungsqualität und praktikabler Rechenzeit zu finden, nutzt diese Arbeit einen systematischen Versuchsaufbau.

Ausgehend von einem festgelegten Referenzwert (Baseline) wurde in jedem Testdurchlauf gezielt nur eine einzige Einstellung verändert, während alle anderen konstant bleiben. So lässt sich objektiv messen, wie sich genau diese eine Anpassung auf die Ergebnisse auswirkt.

Im Rahmen der Versuchsreihe wird zwischen den internen Erstellungsparametern der XAI-Methode und den Evaluierungsparametern des Quantus-Frameworks differenziert (das gradientenbasierte Grad-CAM-Verfahren benötigt im Gegensatz zu LIME keine internen Parameter):

- **LIME-Samples (N):** Die Anzahl der erzeugten Bildvariationen.
- **LIME-Features (K):** Die Anzahl der ausgewählten Superpixel.
- **Quantus-Samples:** Die Anzahl der erzeugten Störungen für die Metrikberechnung.

Insgesamt ergaben sich so pro Modellarchitektur zehn Konfigurationen. Diese wurden an einer festen Stichprobe von 32 korrekt klassifizierten Testbildern (vgl. Kapitel 3.2.1) geprüft – ein Vorgehen, das sich an Sangwan (2024) [15] orientiert, um den Rechenaufwand in einem praktikablen Rahmen zu halten. Die genauen Parameter-Zyklen sind in Tabelle 3 zusammengefasst.

DURCHLAUF	METHODE	LIME: SAMPLES (N)	LIME: FEATURES (K)	QUANTUS: SAMPLES
1	Grad-CAM	-	-	5
2 (Baseline)	Grad-CAM	-	-	10
3	Grad-CAM	-	-	20
4 (Baseline)	LIME	500	50	10
5	LIME	100	50	10
6	LIME	1000	50	10
7	LIME	500	10	10
8	LIME	500	Max	10
9	LIME	500	50	5
10	LIME	500	50	20

Tabelle 3: Ausführungs-Matrix der Parameter-Variation für Grad-CAM und LIME.

Durch diesen systematischen Ansatz wird sichergestellt, dass nicht nur die generelle Leistungsfähigkeit von gradienten- und perturbationsbasierten Methoden miteinander verglichen wird, sondern auch Aussagen darüber getroffen werden können, wie sensitiv die Methoden auf ihre eigene Konfiguration reagieren. Dies bildet die Grundlage für die spätere Diskussion (vgl. Kapitel 6), um den optimalen Kompromiss aus Leistungsfähigkeit und klinischer Praktikabilität zu identifizieren.

4.4 Quantitative Evaluierungsmetriken

Nachdem in den vorherigen Kapiteln die Kriterien für eine verlässliche XAI-Evaluation sowie das zugrunde liegende Quantus-Framework eingeführt wurden, widmet sich dieses Kapitel der konkreten methodischen Umsetzung. Im Folgenden werden die spezifischen quantitativen Metriken definiert, mit denen die drei Kerndimensionen – Erklärungstreue, Robustheit und klinische Effizienz – im experimentellen Ablauf objektiv vergleichbar gemacht werden.

4.4.1 Erklärungstreue

Die Erklärungstreue ist für ein XAI-Verfahren entscheidend (vgl. Kapitel 2.4.1). Zur objektiven Messung der Erklärungstreue wurde in dieser Arbeit die IROF-Metrik (Iterative Removal of Features) herangezogen, da andere gängige Metriken für medizinische Bilddaten spezifische Schwächen aufweisen [40]. So messen ältere Ansätze wie das Pixel-Flipping [55] den Rückgang der Vorhersagewahrscheinlichkeit durch das Entfernen einzelner Pixel, was bei stark korrelierten Bildern fehleranfällig, da das Netzwerk fehlende Informationen aus direkten Nachbarpixeln problemlos interpolieren kann [40]. IROF umgeht dieses Problem der lokalen Pixelkorrelation, indem das Bild zunächst in semantisch zusammenhängende Superpixel unterteilt wird, welche dann als gesamte Einheit entfernt werden [40].



Abbildung 10: Beispielsegmentierung durch SLIC mit Maskierung relevanter Segmente.

Eine alternative Methode zur Vermeidung von Artefakten wäre ROAR (RemOve And Retrain), was jedoch ein rechenintensives Neutraining des Modells erfordert [56]. IROF bietet hier eine wesentlich ressourceneffizientere, aber dennoch statistisch signifikante Alternative [40].

4.4.2 Robustheit

Neben der Erklärungstreue ist die Robustheit eine Voraussetzung für den Einsatz in der klinischen Praxis [18] (vgl. Kapitel 2.4.2). Ein verlässliches XAI-Verfahren darf bei fast identischen Bildern keine völlig unterschiedlichen Erklärungen liefern. Zur objektiven Messung dieser Stabilität wurde in dieser Arbeit die *Local Lipschitz Estimate* herangezogen.

Diese Metrik eignet sich für komplexe medizinische Bilddaten besonders gut, weil sie die Veränderung der Erklärung exakt in Relation zur tatsächlichen Bildänderung setzt. Dadurch liefert sie ein genaues Maß dafür, wie anfällig die Methode an dieser spezifischen Stelle für Störungen ist [16].



Abbildung 11: Beispiel: Instabilität von Grad-CAM gegenüber minimalem Rauschen.

Das Quantus-Framework bietet zur Evaluierung grundsätzlich noch weitere Metriken an, wie etwa die *Average Sensitivity* [39]. In dieser Arbeit wurde die Auswahl jedoch bewusst auf den *Local Lipschitz Estimate* fokussiert. Die Begründung hierfür liegt im medizinischen Kontext: Bei klinischen Assistenzsystemen ist das Worst-Case-Szenario – also die maximale Verfälschung einer ärztlichen Erklärung durch minimale Bildstörungen – das kritischste Risiko für die Patientensicherheit und das Vertrauen des Arztes. Der Lipschitz-Estimate quantifiziert exakt diese Obergrenze der Störanfälligkeit und liefert somit den strengsten und sicherheitsrelevantesten Maßstab für die Verlässlichkeit der Methoden in der Praxis.

4.4.3 Komplexität und Effizienz (Klinische Anwendbarkeit)

Neben den rein mathematischen Metriken wird abschließend auch die operative Praxistauglichkeit erfasst. Hierfür wurde während des experimentellen Ablaufs systemseitig die exakte Berechnungsdauer (in Sekunden) gestoppt, die das jeweilige Verfahren zur Erzeugung einer Heatmap benötigt. Diese Messung dient als Vergleichsgrundlage, um zu beurteilen, inwiefern der zusätzliche Rechenaufwand der Methoden den Anforderungen für zeitkritische klinische Entscheidungen am Point-of-Care gerecht wird.

Die Recheneffizienz wird über die durchschnittliche Latenzzeit Δt definiert, die zur Generierung einer einzelnen Erklärung benötigt wird. Diese ergibt sich aus der Differenz zwischen dem Startzeitpunkt der Anfrage t_{start} und dem Zeitpunkt der fertigen Heatmap t_{end} :

$$\Delta t_{XAI} = t_{end} - t_{start}$$

Formel 14: Berechnung der XAI-Latenzzeit

Da für gradientenbasierte Methoden wie Grad-CAM gilt: $\Delta t \approx t_{Inferenz} + t_{Backprop}$, während für LIME aufgrund der N notwendigen Samples gilt: $\Delta t \approx N * t_{Inferenz} + t_{Surrogate}$, ist diese Metrik entscheidend für die Bewertung der Point-of-Care-Tauglichkeit.

4.5 Qualitative Sanity Checks und Fehleranalyse

Obwohl mathematische Messwerte unerlässlich sind, um Erklärungsverfahren objektiv und vergleichbar zu bewerten, reicht eine rein rechnerische Betrachtung nicht aus. Sie kann die medizinische Plausibilität und den tatsächlichen Nutzen einer Erklärung im Praxisalltag nicht vollständig abbilden [18]. Ein XAI-Verfahren könnte theoretisch gute Werte für Robustheit und Erklärungstreue erzielen, visuell jedoch auf medizinisch völlig bedeutungslose Bereiche fokussieren. Um sicherzustellen, dass die mathematisch generierten Heatmaps auch einer grundlegenden menschlichen und medizinischen Logik folgen, fordern Forschungsarbeiten zur Erklärbarkeit sogenannte *Sanity Checks* [14]. Aus diesem Grund wurde die quantitative Evaluation in dieser Arbeit durch eine gezielte qualitative, visuelle Inspektion ergänzt, welche die medizinische Realität simuliert.

4.5.1 Fehleranalyse im klinischen Kontext (False Positives / False Negatives)

Während die Berechnung quantitativer Metriken wie IROF primär auf korrekt klassifizierten Bildern (vgl. Kapitel 3.2.1) erfolgt, um die Fehlerhaftigkeit des CNN methodisch sauber von der Fehlerhaftigkeit der XAI-Methode zu trennen [14], wird in diesem Schritt die Fehleranalyse methodisch in den Fokus gerückt. In der medizinischen Praxis – insbesondere bei der Nutzung als Clinical Decision Support System (CDSS) – ist es für den behandelnden Arzt unerlässlich zu verstehen, warum ein Modell eine Fehlentscheidung getroffen hat, beispielsweise wenn ein Melanom fälschlicherweise als gutartig eingestuft wurde. Daher soll im Rahmen dieses Sanity Checks qualitativ überprüft werden, inwiefern die XAI-Methoden diesen Aufklärungsprozess unterstützen können [6].

Um diesen klinischen Alltag zu simulieren, wurde aus dem Testdatensatz eine unvoreingenommene Stichprobe von Fehlklassifikationen extrahiert, bei denen die Modelle eine falsche Vorhersage getroffen haben (False Positives und False Negatives). Im nächsten Schritt wurde die am besten bewertete XAI-Methode gezielt auf diese Fehlklassifikationen angewendet. Die qualitative Analyse zeigt, ob sich scheinbar unlogische Fehlentscheidungen des Netzwerks mithilfe der Heatmap visuell nachvollziehen lassen. Ein solcher Erkenntnisgewinn wird bereits von Selvaraju et al. (2017) [10] als einer der Hauptvorteile visueller Erklärungen hervorgehoben. Die Heatmap dient hierbei als diagnostisches Werkzeug, um dem Anwender transparent zu signalisieren, dass der Vorhersage in diesem spezifischen Fall nicht vertraut werden darf, wodurch die Patientensicherheit gewahrt bleibt [6, 18].

4.5.2 Identifikation von Artefakten und dem "Clever Hans"-Effekt

Ein besonderer Fokus der visuellen Inspektion liegt auf der Aufdeckung von unerwünschtem Modell-Bias, insbesondere dem sogenannten „Clever Hans“-Effekt [12] (vgl. Kapitel 6.3). Da reale dermatoskopische Bilder naturgemäß Störfaktoren wie Körperhaare, Blutgefäße, ärztliche Hautmarkierungen oder sichtbare Lineale enthalten [42], wird im Rahmen der Sanity Checks qualitativ überprüft, worauf die Modelle ihre Vorhersage stützen. Konkret wurde visuell analysiert, ob die generierten Heatmaps von Grad-CAM und LIME fälschlicherweise diese irrelevanten Hintergrundartefakte anstelle der eigentlichen Hautläsion als Entscheidungsgrundlage markieren. Diese Überprüfung dient dem methodischen Nachweis, ob die jeweilige XAI-Methode in der Lage ist, ein solches fehlerhaftes Lernverhalten des CNNs transparent aufzudecken, um die klinische Anforderung zu erfüllen, den Arzt vor einer falschen Sicherheit zu bewahren [6].

4.6 Statistische Auswertung

Um zu überprüfen, ob die im Experiment beobachteten Leistungsunterschiede zwischen Grad-CAM und LIME nicht nur zufällig sind, sondern systematische Gültigkeit besitzen, wird eine statistische Signifikanzanalyse durchgeführt. Da beide XAI-Methoden auf exakt denselben 32 Testbildern (True Positives) evaluiert werden, handelt es sich methodisch um gepaarte Stichproben. Da bei Metriken zur Erklärungsqualität (wie dem IROF und dem Local Lipschitz Estimate) nicht zwingend von einer Normalverteilung der Daten ausgegangen werden kann, wird in dieser Arbeit der nicht-parametrische Wilcoxon-Vorzeichen-Rang-Test für den direkten Methodenvergleich herangezogen [57, 58]. Das Signifikanzniveau beträgt dabei $\alpha = 0,05$, wodurch die Irrtumswahrscheinlichkeit – also das Risiko, einen beobachteten Leistungsunterschied fälschlicherweise als systematisch einzustufen, obwohl dieser lediglich auf Zufall beruht – auf maximal 5 % begrenzt wird. Zeigt der Test signifikante Ergebnisse, wird ergänzend ein 95%-Konfidenzintervall berechnet [18]. Dieses gibt eine konkrete Spanne an, in der sich der tatsächliche Leistungsunterschied zwischen den beiden XAI-Methoden mit 95-prozentiger Sicherheit bewegt.

Da ein p-Wert prinzipiell nur die statistische Signifikanz belegt, jedoch keine direkte Aussage über die praktische Bedeutsamkeit eines Effekts zulässt [59], wird für die vorliegende Stichprobe ($n = 32$) ergänzend die *Rangbiseriale Korrelation* (r_{rb}) berechnet [60]. Dieser Wert übersetzt die theoretische Signifikanz in praktische Relevanz – eine Voraussetzung, um den echten klinischen Mehrwert der Methoden beurteilen zu können.

5. Ergebnisse

Dieses Kapitel präsentiert die empirischen Ergebnisse der durchgeführten Experimente auf dem HAM10000-Datensatz. Zunächst werden die Metriken zur Basis-Performance der CNNs auf dem Testdatensatz berichtet. Darauf aufbauend werden die quantitativen Evaluationsergebnisse der XAI-Methoden Grad-CAM und LIME hinsichtlich Erklärungstreue, Robustheit und Recheneffizienz dargelegt. Den Abschluss bildet die Präsentation der Heatmaps aus der qualitativen visuellen Inspektion der Fehlklassifikationen.

5.1 Modell-Performance (Klassifikationsgüte)

Bevor die Erklärungsqualität der XAI-Methoden evaluiert werden kann, muss sichergestellt sein, dass die zugrunde liegenden Modelle eine verlässliche Entscheidungsgrundlage bieten. Auf dem ungesehenen Testdatensatz (1.503 Bilder) erreichte das ResNet-101 eine Gesamtgenauigkeit von 89,02 % bei einem gewichteten Durchschnitt über Präzision, Recall und F1-Score von jeweils ~0,89. Das MobileNetV3 erzielte eine Gesamtgenauigkeit von 86,16 % und einen gewichteten F1-Score von ~0,86 (vgl. Tabelle 4 & 5).

KLASSE (SUPPORT)	PRÄZISION	RECALL	F1-SCORE
akiec (49)	0.8367	0.8367	0.8367
bcc (77)	0.9041	0.8571	0.8800
bkl (165)	0.8311	0.7455	0.7859
df (17)	0.9286	0.7647	0.8387
mel (167)	0.8205	0.5749	0.6761
nv (1006)	0.9058	0.9751	0.9392
vasc (22)	0.9474	0.8182	0.8780
Genauigkeit (accuracy)			0.8902
Macro avg.	0.8820	0.7960	0.8335
Weighted avg.	0.8867	0.8902	0.8847

Tabelle 4: Detaillierter Klassifikationsbericht für das **ResNet-101** auf dem Testdatensatz (N=1.503).

KLASSE (SUPPORT)	PRÄZISION	RECALL	F1-SCORE
akiec (49)	0.6604	0.7143	0.6863
bcc (77)	0.8529	0.7532	0.8000
bkl (165)	0.7654	0.7515	0.7584
df (17)	0.8750	0.8235	0.8485
mel (167)	0.7391	0.5090	0.6028
nv (1006)	0.8981	0.9553	0.9258
vasc (22)	0.9474	0.8182	0.8780
Genauigkeit (accuracy)			0.8616
Macro avg.	0.8198	0.7607	0.7857
Weighted avg.	0.8563	0.8616	0.8557

Tabelle 5: Detaillierter Klassifikationsbericht für das **MobileNetV3** auf dem Testdatensatz (N=1.503).




Abbildung 12: Gruppierendes Balkendiagramm der F1-Scores. Vergleicht die Performance beider Modelle über alle sieben Hautläsionsklassen.

Während die überrepräsentierte Klasse der melanozytären Nävi (nv) von beiden Modellen mit F1-Scores von 0,94 (ResNet-101) bzw. 0,93 (MobileNetV3) sehr sicher erkannt wurde, fielen die Vorhersagen bei kritischen Minderheitsklassen wie dem Melanom (mel) mit F1-Scores von 0,68 und 0,60 deutlich schwächer aus.

Die berechneten Konfusionsmatrizen (vgl. Abbildung 13 & 14) visualisieren die genaue Verteilung der True Positives, False Positives und False Negatives über alle sieben Hautläsionsklassen.

5. Ergebnisse

Hier wird im Detail ersichtlich, in welchen spezifischen Fällen die Modelle Läsionen verwechseln. Abseits der Hauptdiagonalen zeigt sich dies konkret an der kritischen Klasse der Melanome: Das MobileNetV3 stufte in 65 Fällen ein malignes Melanom fälschlicherweise als gutartigen Nävus ein, während dem ResNet-101 dieser kritische Fehler in 62 Fällen unterlief.




Abbildung 13: Konfusionsmatrix für ResNet-101.




Abbildung 14: Konfusionsmatrix für MobileNetV3.

5.2 Robustheit

In diesem Kapitel wird die Stabilität der Erklärungen gegenüber minimalen Eingabestörungen evaluiert. Anders als bei der IROF-Metrik stehen hier niedrigere Werte für ein stabileres und somit robusteres Erklärungsverfahren. Ein hoher Messwert signalisiert dagegen, dass die Methode schon bei minimalem Bildrauschen sehr störanfällig reagiert.

5.2.1 Basis-Vergleich der XAI-Methoden (Durchlauf 4)

Für den architekturübergreifenden Vergleich zwischen Grad-CAM und LIME werden zunächst die Ergebnisse des Basis-Setups (Grad-CAM: Durchlauf 2, LIME: Durchlauf 4 mit $N = 500$ Samples und $K = 50$ Features) auf dem Test-Batch von 32 True-Positive-Bildern analysiert.

MODELL	XAI-METHODE	LOCAL LIPSCHITZ ESTIMATE (MEAN $\pm$ STD)	MIN	MAX
ResNet-101	Grad-CAM	0.40 $\pm$ 0.12	0.24	0.84
ResNet-101	LIME	3.52 $\pm$ 0.70	2.27	4.63
MobileNetV3	Grad-CAM	0.64 $\pm$ 0.24	0.33	1.22
MobileNetV3	LIME	3.94 $\pm$ 0.54	1.76	5.09

Tabelle 6: Robustheit (Local Lipschitz Estimate) im Basis-Setup.




Abbildung 15: Gruppierter Violin-Plot, der die Verteilung der Local Lipschitz Estimates für Grad-CAM und LIME vergleichend für ResNet-101 und MobileNetV3 im Basis-Setup zeigt.

Die Auswertung in Tabelle 6 zeigt deutliche Unterschiede bei der Stabilität der beiden XAI-Konzepte. Grad-CAM erweist sich dabei unabhängig von der gewählten Netzwerkarchitektur als äußerst robust. Auf dem ResNet-101 erzielt Grad-CAM einen niedrigen Lipschitz-Wert von 0.40 (Std = 0.12). LIME hingegen zeigt sich auf demselben Modell mit einem mittleren Score von 3.52 (Std = 0.70) als instabil. Die Erklärungen von LIME weichen bei minimalen Bildstörungen signifikant ab. Dieses Ergebnis deckt sich exakt mit den Erkenntnissen von Alvarez-Melis und Jaakkola (2018) [16]: Während gradientenbasierte Ansätze bei ähnlichen Eingaben zu ähnlichen Gradientenflüssen führen, macht die Natur von LIME die generierten Erklärungen anfällig für kleinstes Rauschen.

Zudem zeigt sich, dass die Robustheit der Erklärungen stark von der gewählten Modellarchitektur abhängt. Das effiziente MobileNetV3 reagiert auf Bildrauschen sensibler als das tiefe ResNet-101. Diese modellspezifische Instabilität überträgt sich direkt auf die XAI-Methoden: Der Lipschitz-Wert von Grad-CAM verschlechtert sich beim MobileNetV3 auf 0.64, und auch LIME verzeichnet mit 3.94 den instabilsten Durchschnittswert der Basis-Testreihe.

Um die statistische Relevanz dieser starken Abweichungen zu validieren, wurde der Wilcoxon-Vorzeichen-Rang-Test auf die Stichprobe angewendet (vgl. Kapitel 4.6). Dieser bestätigt, dass der beobachtete Stabilitätsvorteil von Grad-CAM kein Zufall ist. Die Robustheit von Grad-CAM ist bei beiden Modellen im Vergleich zu LIME statistisch hochsignifikant ($p < 0.001$). Da bei der Lipschitz-Metrik niedrigere Werte eine höhere Stabilität bedeuten, drückt sich der gemessene Stabilitätsvorteil von Grad-CAM beim ResNet-101 in einer mittleren Differenz von -3,12 aus, wobei das 95%-Konfidenzintervall der Differenz bei [-3,37; -2,88] liegt. Da Grad-CAM in ausnahmslos jedem Testbild der Stichprobe stabilere Werte als LIME erzielt, resultiert dies in einer *Rangbiseriellen Korrelation* von $|r_{rb}| = 1,0$ – einem maximalen statistischen Effekt, der den Stabilitätsunterschied in der Praxis beweist. Auch beim MobileNetV3 bestätigt sich dieses Bild: Hier erzielt Grad-CAM einen durchschnittlichen Wert von -3,30, was sich in einem 95%-Konfidenzintervall der Differenz von [-3,54; -3,06] niederschlägt, sowie ebenfalls einer perfekten *Rangbiseriellen Korrelation* von $|r_{rb}| = 1,0$ aufweist.

5.2.2 Parametersensitivität – LIME (Durchlauf 4, 5, 6, 7, 8)

Aufbauend auf den Resultaten des Basisvergleichs stellt dieser Abschnitt die gemessenen Lipschitz-Werte der LIME-Methode unter Variation der Hyperparameter dar. Dabei wird rein quantitativ betrachtet, wie sich eine Anpassung der Samples (N) und Superpixel (K) auf die Stabilität der generierten Heatmaps auswirkt.

Betrachtet man den Einfluss der Samples (N), zeigt sich: Mehr künstlich gestörte Bilder führen nur zu einer minimalen Änderung der Robustheit. Eine Verzehnfachung des Rechenaufwands von $N = 100$ (Durchlauf 5) auf $N = 1000$ (Durchlauf 6) ändert den Lipschitz-Wert beim ResNet-101 lediglich von 3,58 auf 3,45.

5. Ergebnisse

Ein fast identisches Bild zeigt sich beim MobileNetV3, wo die Erhöhung auf 1000 Samples die Stabilität kaum messbar von 3,99 auf 3,93 verändert. Die Messdaten belegen somit, dass das grundlegende Rauschproblem von LIME nicht einfach durch mehr Rechenleistung gelöst werden kann.




Abbildung 16: Einfluss der Perturbationsanzahl (N) auf die Robustheit (Lipschitz-Wert) von LIME bei ResNet-101 und MobileNetV3.

Bei der Auswahl der Superpixel (K) zeichnet sich eine vergleichbare Tendenz ab. Dieser Parameter bestimmt, wie viele relevante Bereiche LIME für die Heatmap berücksichtigt. Beschränkt man die Erklärung auf wenige Merkmale ($K = 10$, Durchlauf 7), reagiert das Verfahren störanfälliger. Die Lipschitz-Werte steigen in diesem Fall auf 3,84 beim ResNet-101 und 3,96 beim MobileNetV3. Bezieht die Methode hingegen alle verfügbaren Superpixel ein ($K = \text{Max}$, Durchlauf 8), stabilisieren sich die Erklärungen wieder. Die Werte sinken daraufhin auf 3,43 beim ResNet-101 und auf 3,86 beim MobileNetV3.




Abbildung 17: Einfluss der Superpixel-Auswahl (K) auf die Robustheit von LIME bei ResNet-101 und MobileNetV3.

Die Auswertung der Parameter zeigt, dass eine Reduzierung der Merkmale auf wenige Superpixel ($K = 10$) zu den höchsten Werten bei der *Local Lipschitz Estimate* führt. In dieser Konfiguration reagiert die Methode also besonders empfindlich auf Bildstörungen. Erlaubt man LIME hingegen die Nutzung aller verfügbaren Segmente ($K = \text{Max}$), sinken die Werte wieder. Dennoch verdeutlichen die Daten, dass LIME selbst in dieser dichten Einstellung deutlich unregelmäßigere Erklärungen liefert als das Grad-CAM-Verfahren.

5.2.3 Sensitivität der Evaluierungsmetrik – Local Lipschitz Estimate (Durchlauf 1, 2, 3, 4, 9, 10)

Dieses Kapitel untersucht, wie sich die Anzahl der gewählten Evaluierungs-Samples im Quantus-Framework auf den *Local Lipschitz Estimate* auswirkt. Dazu werden die Durchläufe 1 und 3 für Grad-CAM sowie die Durchläufe 9 und 10 für LIME ausgewertet. Durchlauf 2 und 4 werden als entsprechende Basis-Werte in den Ergebnissen mit dargestellt.

Bei Grad-CAM verändern die unterschiedlichen Framework-Einstellungen die Ergebnisse kaum. Auf dem MobileNetV3 bleibt der Lipschitz-Wert mit 0,65 bei 5 Evaluierungs-Samples (Durchlauf 1) und 0,69 bei 20 Evaluierungs-Samples (Durchlauf 3) fast gleich. Auch beim ResNet-101 zeigen die Scores mit 0,38 (Durchlauf 1) und 0,41 (Durchlauf 3) nur minimale Unterschiede. Das unterstreicht die grundlegende Stabilität dieser Methode.

Ein ähnliches Bild zeigt sich bei LIME, wo die Werte ebenfalls stabil bleiben. Auf dem MobileNetV3 stagnieren die mittleren Werte auf einem Plateau von 3,83 (5 Evaluierungs-Samples, Durchlauf 9) über 3,94 (10 Evaluierungs-Samples, Durchlauf 4) bis 3,98 (20 Evaluierungs-Samples, Durchlauf 10). Beim ResNet-101 bleiben die Scores mit 3,32 (Durchlauf 9), 3,52 (Durchlauf 4) und 3,59 (Durchlauf 10) ebenfalls relativ konstant.

Da die großen Abstände zwischen den beiden Verfahren in allen Einstellungen bestehen bleiben, ist die Instabilität ein Problem von LIME selbst und liegt nicht am Testaufbau. Weil mehr Evaluierungs-Samples die Kennzahlen kaum verändern, die Rechenzeit aber linear verdoppeln, reicht eine kleine Evaluierungs-Samplesgröße von 10 im Quantus-Framework aus.


5.3 Erklärungstreue

In diesem Kapitel werden die Ergebnisse zur Erklärungstreue der beiden untersuchten XAI-Methoden präsentiert. Die Erklärungstreue misst, inwieweit die generierten Heatmaps den tatsächlichen internen Entscheidungsprozess des Modells widerspiegeln. Ein höherer IROF-Wert indiziert eine präzisere und treuere Erklärung.

5.3.1 Basis-Vergleich der XAI-Methoden (Durchlauf 4)

Für den architekturübergreifenden Vergleich zwischen der Grad-CAM und LIME werden zunächst die Ergebnisse des Basis-Setups (Grad-CAM: Durchlauf 2, LIME: Durchlauf 4 mit $N = 500$ Samples und $K = 50$ Features) auf dem Test-Batch von 32 True-Positive-Bildern analysiert.

MODELL	XAI-METHODE	IROF (MEAN $\pm$ STD)	MIN	MAX
ResNet-101	Grad-CAM	82.71 $\pm$ 15.23	40.12	98.97
ResNet-101	LIME	75.31 $\pm$ 27.12	-31.51	97.20
MobileNetV3	Grad-CAM	65.67 $\pm$ 10.70	45.65	97.51
MobileNetV3	LIME	76.56 $\pm$ 15.73	20.61	95.04

Tabelle 7: Erklärungstreue (IROF) im Basis-Setup.**Abbildung 18:** Gruppiertes Violin-Plot, der die Verteilung der IROF-Werte für Grad-CAM und LIME vergleichend für ResNet-101 und MobileNetV3 im Basis-Setup zeigt.

Bei der Betrachtung des ResNet-101 erweist sich Grad-CAM als überlegen. Sie erzielt mit einem mittleren IROF-Wert von 82.71 nicht nur die höchste absolute Erklärungstreue im Test, sondern weist mit einer Standardabweichung von 15.23 auch eine vergleichsweise stabile Erklärungsqualität auf. LIME erreicht auf demselben Modell einen niedrigeren Mittelwert von 75.31 und zeigt zudem eine hohe Varianz (Std = 27.12). Auffällig ist hierbei der negative Ausreißer von LIME (-31.51). Ein negativer IROF-Wert bedeutet einen Widerspruch in sich: Das Löschen der Bildbereiche, die LIME eigentlich als besonders wichtig eingestuft hat, führt dazu, dass die Vorhersagewahrscheinlichkeit des Netzwerks für die richtige Klasse sogar steigt. Dies deutet darauf hin, dass LIME die tatsächliche Logik des Modells in diesen Einzelfällen inkorrekt abgebildet hat.

Ein entgegengesetztes Bild zeigt sich bei der Evaluation auf der effizienten Architektur des MobileNetV3. Hier fällt die Leistung von Grad-CAM deutlich ab (Mean = 65.67), während LIME mit einem IROF-Wert von 76.56 die präziseren Erklärungen generiert. Im Gegensatz zum ResNet-101 treten bei der Anwendung von LIME auf das MobileNetV3 keine negativen Ausreißer auf.

Mit einem Minimalwert von 20,61 deutet dies darauf hin, dass die Annäherung des Verfahrens bei dieser speziellen Netzwerkarchitektur stabiler funktioniert.

Zur statistischen Absicherung dieses Modellabhängigen Verhaltens wurde auch hier ergänzend eine Signifikanzanalyse durchgeführt. Für das ResNet-101 erwies sich die Überlegenheit von Grad-CAM gegenüber LIME im Wilcoxon-Test als statistisch signifikant ($p = 0.0057$), wobei das 95%-Konfidenzintervall der Differenz (7,40 IROF-Punkte) bei $[1,05; 13,76]$ liegt. Zudem belegt die *Rangbiseriale Korrelation* mit einem $|r_{rb}| = 0,549$ starken Effekt, was die hohe praktische Relevanz unterstreicht. Für das effiziente MobileNetV3 bestätigt der Test hingegen mathematisch, dass LIME hochsignifikant treuere Erklärungen liefert als Grad-CAM ($p < 0.001$), was sich in einem 95%-Konfidenzintervall der Differenz (10,89 IROF-Punkte) von $[-16,41; -5,38]$ niederschlägt. Dass dieser Unterschied auch praktisch ins Gewicht fällt, belegt die *Rangbiseriale Korrelation*: Der Wert von $|r_{rb}| = 0,746$ entspricht einem starken Effekt.

5.3.2 Parametersensitivität – LIME (Durchlauf 4, 5, 6, 7, 8)

Die quantitative Untersuchung der Evaluierungs-Samples im Quantus-Framework zeigt architekturübergreifend keine großen Auswirkungen auf die berechneten Robustheits- und Erklärungstreue-Metriken. Bei Grad-CAM stagniert der Local Lipschitz Estimate auf dem MobileNetV3 unabhängig von der Sample-Anzahl zwischen 0,65 (5 Samples, Durchlauf 1) und 0,69 (20 Samples, Durchlauf 3); ein ähnlich stabiles Verhalten zeigt sich beim ResNet-101 (0,38 bis 0,41).

Auch die LIME-Scores verbleiben auf einem konstanten Plateau von rund 3,90 auf dem MobileNetV3 und 3,50 auf dem ResNet-101. Da die signifikanten Leistungsabstände zwischen den beiden XAI-Konzepten in allen Konfigurationen unverändert bestehen bleiben, erweist sich die gewählte Framework-Einstellung als unabhängig vom Versuchsaufbau. Für die statistische Validierung ist eine Stichprobengröße von 10 Samples im Framework somit vollständig ausreichend, während höhere Werte lediglich die Rechenzeit linear verdoppeln.




Abbildung 19: Einfluss der Perturbationsanzahl (N) auf die Erklärungstreue (IROF) von LIME bei ResNet-101 und MobileNetV3.

5. Ergebnisse

Bei der Auswahl der Superpixel (K) zeigen sich bei beiden Extremwerten deutliche Instabilitäten auf dem ResNet-101. Reduziert man die Merkmale auf $K = 10$ (Durchlauf 7), bricht der IROF-Score durch einen extremen Ausreißer von -227,12 ein. Ein sehr ähnliches Problem zeigt sich bei der maximal dichten Heatmap ($K = \text{Max}$, Durchlauf 8), wo der mittlere Wert auf 69,94 sinkt und ein Ausreißer von -223,76 auftritt.

Sowohl eine zu starke Beschränkung als auch zu viele gleichzeitige Bildmanipulationen führen beim komplexen ResNet-101 zu Daten außerhalb der gelernten Verteilung (*Out-of-Distribution*). Das MobileNetV3 verhält sich in diesen Durchläufen mit Werten von 76,39 ($K = 10$) und 76,85 ($K = \text{Max}$) deutlich stabiler.




Abbildung 20: Einfluss der Superpixel-Auswahl (K) auf die Erklärungstreue (IROF) von LIME bei ResNet-101 und MobileNetV3.

5.4 Recheneffizienz und klinische Anwendbarkeit

In diesem Abschnitt werden die Berechnungszeiten der XAI-Methoden evaluiert. Die gemessenen Zeiten umfassen ausschließlich die Generierung der Erklärungen pro Läsion in Sekunden für die 32 True-Positive-Bilder.

Für die Auswertung der Recheneffizienz wurde auf eine separate zeitliche Darstellung der Durchläufe 1 und 3 (Grad-CAM) sowie 9 und 10 (LIME) bewusst verzichtet. Diese Durchläufe werden hier nicht explizit gemessen, da für diese Arbeit nur die reine Recheneffizienz der XAI-Methoden selbst relevant ist. Da sich in diesen Durchläufen lediglich die Parameter des Quantus-Frameworks für die spätere Auswertung ändern, bleibt die Erstellungsdauer der Heatmaps davon völlig unberührt. Die Zeiten der Durchläufe 1, 3, 9 und 10 basieren somit exakt auf den jeweiligen Basis-Werten aus Durchlauf 2 (für Grad-CAM) und Durchlauf 4 (für LIME).

5.4.1 Basis-Vergleich und Architektureinfluss

Die Tabellen 8 und 9 stellen die Ergebnisse für das ResNet-101 und das MobileNetV3 gegenüber.

METHODE	PARAMETER-SETUP	ZEIT PRO BILD (MEAN $\pm$ STD)
Grad-CAM	Basis (Durchlauf 2)	0,0157 $\pm$ 0,0042 s
LIME	500 Samples, 50 Features (Basis, Durchlauf 4)	4,4311 $\pm$ 0,0176 s
LIME	100 Samples, 50 Features (Durchlauf 5)	1,1626 $\pm$ 0,0176 s
LIME	1000 Samples, 50 Features (Durchlauf 6)	8,5943 $\pm$ 0,1435 s
LIME	500 Samples, 10 Features (Durchlauf 7)	4,4407 $\pm$ 0,0422 s
LIME	500 Samples, Max Features (Durchlauf 8)	4,4382 $\pm$ 0,0340 s

Tabelle 8: Rechenzeit pro Bild in Sekunden (ResNet-101).

METHODE	PARAMETER-SETUP	ZEIT PRO BILD (MEAN $\pm$ STD)
Grad-CAM	Basis (Durchlauf 2)	0,0120 $\pm$ 0,0023 s
LIME	500 Samples, 50 Features (Basis, Durchlauf 4)	2,1983 $\pm$ 0,0685 s
LIME	100 Samples, 50 Features (Durchlauf 5)	0,7415 $\pm$ 0,0191 s
LIME	1000 Samples, 50 Features (Durchlauf 6)	4,0325 $\pm$ 0,1132 s
LIME	500 Samples, 10 Features (Durchlauf 7)	2,1993 $\pm$ 0,0548 s
LIME	500 Samples, Max Features (Durchlauf 8)	2,1969 $\pm$ 0,0506 s

Tabelle 9: Rechenzeit pro Bild in Sekunden (MobileNetV3).

Der Datenvergleich des Basis-Setups zeigt signifikante Unterschiede in der Recheneffizienz. Grad-CAM generiert die Heatmaps architekturübergreifend in Bruchteilen einer Sekunde (ResNet-101: 0,016 s; MobileNetV3: 0,012 s).

Die Erklärungsgenerierung mittels LIME beansprucht im Basis-Setup ($N = 500$, $K = 50$) mit durchschnittlich 4,43 Sekunden auf dem ResNet-101 und 2,20 Sekunden auf dem MobileNetV3 deutlich mehr Zeit. Gleichzeitig belegen die Messwerte, dass die Ausführungsdauer von LIME stark von der Netzwerkarchitektur abhängt: Auf dem MobileNetV3 erfolgt die Berechnung doppelt so schnell wie auf dem ResNet-101.

5.4.2 Einfluss der LIME-Parameter auf die Effizienz

Da die Methode LIME im Vergleich zu Grad-CAM den zeitlichen Flaschenhals im Klassifizierungsprozess darstellt, wurde der Einfluss der Parameter Samples (N) und Features (K) auf die Rechenzeit isoliert betrachtet.

Die Messdaten belegen (Tabelle 8 und 9) zunächst, dass die Rechenzeit fast linear mit der Anzahl der generierten Bildvariationen skaliert. Eine Reduktion auf $N = 100$ Samples senkt die Erstellungsdauer beim MobileNetV3 auf schnelle 0,74 Sekunden, während sie beim ResNet-101 auf 1,16 Sekunden fällt. Erhöht man die Sample-Zahl hingegen von den standardmäßigen 500 auf 1000, verlängert sich die Wartezeit beim MobileNetV3 auf 4,03 Sekunden und beim ResNet-101 auf 8,59 Sekunden. Dies verdeutlicht, dass die schiere Menge der durchzuführenden Durchläufe durch das CNN den primären Rechenaufwand der Methode bestimmt.

Ein völlig anderes Verhalten zeigt sich hingegen bei der Variation der für die Erklärung genutzten Superpixel (K), während die Samples konstant auf der Basis von $N = 500$ belassen wird. Reduziert man die Erklärung auf nur wenige Superpixel ($K = 10$) oder bezieht alle verfügbaren Bildbereiche ein ($K = \text{Max}$), bleibt die Rechenzeit nahezu exakt auf dem Basisniveau. Auf dem ResNet-101 schwankt die Dauer bei diesen Anpassungen lediglich minimal zwischen 4,43 und 4,44 Sekunden; auf dem MobileNetV3 verbleibt sie konstant bei rund 2,20 Sekunden. Die Messungen zeigen somit, dass die Parameter der Feature-Selektion die Effizienz der Methode nicht beeinflussen und die zeitliche Auslastung fast ausschließlich durch die Anzahl der Perturbationen dominiert wird.




Abbildung 21: Balkendiagramm, das die durchschnittliche Rechenzeit (in Sekunden) der verschiedenen LIME-Konfigurationen für beide Modelle darstellt.

5.5 Qualitative Sanity Checks (Fehleranalyse)

Um die quantitativen Evaluationsergebnisse zu ergänzen und den diagnostischen Nutzen der XAI-Methoden bei Fehlentscheidungen zu demonstrieren, wurde abschließend eine qualitative visuelle Inspektion (Sanity Checks) durchgeführt. Explainable AI entfaltet im medizinischen Kontext einen Teil ihres Wertes bei der Fehleranalyse, um nachzuvollziehen, warum ein Modell eine inkorrekte Klassifikation gestellt hat. Hierfür wurde aus dem Testdatensatz eine gezielte Stichprobe von Fehlklassifikationen (False Negatives und False Positives) beider Modelle extrahiert. Auf diese Bilder wurde Grad-CAM angewendet, um die Heatmaps der Netzwerke im Moment der Fehlentscheidung visuell auszugeben.




Abbildung 22: Qualitative Fehleranalyse (Sanity Checks). Bild-Grid mit 3 Repräsentativen Fehlklassifikationen.

Die generierten Heatmaps der Fehlklassifikationen (vgl. Abbildung 22) zeigen, auf welche spezifischen Bildregionen die CNNs ihren Fokus stützten, anstatt die eigentliche Hautläsion zu analysieren. Reale dermatoskopische Bilder, weisen eine Vielzahl optischer Störfaktoren auf, darunter Körperbehaarung, medizinische Hautmarkierungen, Lineale oder dunkle Vignettenränder.




Abbildung 23: Grad-CAM-Anzeige einer Fehlentscheidung basierend auf Hintergrundartefakten.

Die visuelle Inspektion der Heatmaps offenbart in diesen fehlerhaften Fällen, dass das Modell die höchste Relevanz nicht der Läsion zuordnete. Stattdessen konzentriert sich die Aufmerksamkeit des Netzwerks stark auf die genannten Bildartefakte im Hintergrund (vgl. Abbildung 23). Die Heatmaps visualisieren somit das Auftreten des sogenannten "Clever Hans"-Effekts [12] (vgl. Kapitel 6.3) in der medizinischen Bildklassifikation. Dadurch wird sichtbar, dass die Netzwerke ihre Vorhersage auf künstliche Zusammenhänge im Bildhintergrund stützen, anstatt die tatsächlich relevanten Merkmale der Läsion zu analysieren.

5.6 Modellabhängigkeit der erlernten Repräsentationen

Neben der Fehleranalyse (Sanity Checks) liefert die visuelle Inspektion der Heatmaps ein weiteres zentrales Ergebnis: Die generierten Erklärungen hängen von der zugrunde liegenden Netzwerkarchitektur ab [13]. Wendet man dieselbe XAI-Methode auf exakt dasselbe Eingabebild an, resultieren bei ResNet-101 und MobileNetV3 abweichende Heatmaps, selbst wenn beide Modelle die Läsion übereinstimmend korrekt klassifizieren (vgl. Abbildung 24).




Abbildung 24: Gegenüberstellung der erlernten Merkmalsrepräsentationen.

6. Diskussion

In diesem Kapitel werden die im experimentellen Teil gewonnenen Ergebnisse interpretiert und kritisch bewertet. Ziel ist es, die in der Einleitung formulierten Forschungsfragen zu beantworten und die Leistungsfähigkeit der XAI-Methoden Grad-CAM und LIME im Spannungsfeld zwischen technischer Zuverlässigkeit und medizinischer Anwendbarkeit einzuordnen.

6.1 Interpretation der Klassifikationsleistung als Ausgangsbasis

Bevor die Erklärungsqualität diskutiert werden kann, muss die zugrunde liegende Modell-Performance betrachtet werden. Die Ergebnisse zeigen, dass das tiefe ResNet-101 (Accuracy: 89,02 %) das effiziente MobileNetV3 (Accuracy: 86,16 %) auf dem ungesehenen Testdatensatz übertrifft. Wie die Konfusionsmatrizen (vgl. Kapitel 5.1, Abbildung 13 & 14) offenbaren, haben beide Modelle jedoch signifikante Probleme bei der Erkennung der kritischen Minderheitsklasse Melanom (mel), was sich in vergleichsweise niedrigen F1-Scores von 0,67 bzw. 0,60 niederschlägt.

Diese systematischen Verwechslungen von malignen Melanomen mit gutartigen Nävi unterstreichen die in der Forschungsliteratur beschriebene Notwendigkeit von Explainable AI in der medizinischen Bildverarbeitung [6]. Da die Modelle Fehler machen, darf das medizinische Personal der reinen Wahrscheinlichkeitsausgabe nicht blind vertrauen. Die eingesetzten XAI-Verfahren müssen in der Lage sein, transparent aufzuzeigen, auf welcher visuellen Basis eine (möglicherweise falsche) Entscheidung getroffen wurde.

6.2 Beantwortung der Forschungsfragen

Im Kern dieser Arbeit stand die Untersuchung, inwiefern sich gradientenbasierte und perturbationsbasierte XAI-Methoden hinsichtlich ihrer Robustheit, Erklärungstreue, Recheneffizienz und klinische Anwendbarkeit unterscheiden. Um die übergeordnete Hauptforschungsfrage zu beantworten, werden im Folgenden die in Kapitel 1.2 formulierten Teilfragen diskutiert.

6.2.1 Robustheit

Teilfrage 1: *Wie stark variieren die von den XAI-Methoden generierten Erklärungen (Heatmaps) bei künstlich herbeigeführten Bildtransformationen, sofern die eigentliche Vorhersage des Modells unverändert bleibt?*

Die Ergebnisse liefern hierauf eine eindeutige Antwort: Die Erklärungen von LIME variieren bei minimalen Bildstörungen um den Faktor sechs bis neun stärker als die von Grad-CAM.

Auf dem ResNet-101 erzielt Grad-CAM einen hervorragenden Wert von 0,40. LIME reagiert mit einem Wert von 3,52 fast neunmal so empfindlich auf minimale Bildstörungen. Ein ähnliches Bild zeigt sich beim MobileNetV3: Auch hier ist Grad-CAM (Score: 0,64) weitaus stabiler als LIME (Score: 3,94).

Dieser enorme Stabilitätsunterschied liegt in der Funktionsweise der Ansätze begründet. Perturbationsbasierte Verfahren wie LIME unterteilen das Eingabebild in Superpixel und maskieren diese zufällig. Schon winziges Rauschen im Originalbild verändert diese Superpixel-Grenzen geringfügig, was beim Training des Ersatzmodells unweigerlich zu schwankende Erklärungen führt [16]. Grad-CAM nutzt hingegen den internen Gradientenfluss. Da tiefe neuronale Netzwerke von Natur aus eine gewisse Toleranz gegenüber leichtem Rauschen besitzen, bleiben auch die daraus abgeleiteten Gradienten und Heatmaps konstant, solange die Modellentscheidung stabil bleibt [39].

Zudem verdeutlichen die Daten, dass beide XAI-Verfahren auf dem ResNet-101 robuster agieren als auf dem MobileNetV3. Dies lässt sich durch die starke Überparametrisierung des ResNe-101 erklären, die Fehler besser toleriert. Das MobileNetV3 ist auf Effizienz getrimmt. Dadurch bricht der Informationsfluss im Netzwerk leichter ab. Das macht die Erklärungen insgesamt weniger stabil. Dass es sich bei diesem Stabilitätsunterschied zwischen den beiden XAI-Verfahren nicht um ein zufälliges Ergebnis der Stichprobe handelt, belegt der durchgeführte Wilcoxon-Test, der die Überlegenheit von Grad-CAM Modellübergreifend als hochsignifikant bestätigt (vgl. Kapitel 5.2.1). Der maximale statistische Effekt von $|r_{rb}| = 1,0$ beweist zudem, dass dieser Stabilitätsvorteil von Grad-CAM auch für den klinischen Praxisalltag hochrelevant ist.

Zusammenfassend liefert Grad-CAM die deutlich robusteren Erklärungen. Da stark variierende Erklärungen bei nahezu identischen Läsionen das Vertrauen des medizinischen Personals in ein Assistenzsystem untergraben [61], ist Grad-CAM in puncto Robustheit die verlässlichere Wahl.

6.2.2 Erklärungstreue

Teilfrage 2: *Korrelieren die von der jeweiligen XAI-Methode als wichtig markierten Bildbereiche tatsächlich mit dem internen Klassifikationsergebnis des Modells?*

Die quantitative Evaluation der Erklärungstreue zeigt, dass die untersuchten XAI-Methoden die Entscheidungsprozesse der Modelle prinzipiell abbilden können. Eine universelle Zuverlässigkeit lässt sich nicht feststellen. Die Ergebnisse verdeutlichen vielmehr, dass die Qualität der Erklärung von der Kompatibilität zwischen dem XAI-Verfahren und der zugrunde liegenden Modellarchitektur abhängt.

Bei komplexen, tiefen Netzwerkarchitekturen wie dem ResNet-101 erweist sich der direkte Zugriff auf den Gradientenfluss als vorteilhaft. Da Grad-CAM die exakten Gradienten der letzten Faltungsschicht auswertet, kann es die Entscheidungsgrundlage des tiefen Netzwerks rekonstruieren.

Perturbationsbasierte Verfahren wie LIME stoßen hier hingegen an methodische Grenzen.

Da LIME das Modellverhalten ausschließlich über externe Bildstörungen und Segmentierung annähert, führt dieser rein Black-Box-basierte Ansatz zu Ungenauigkeiten.

Die negativen IROF-Ausreißer bei LIME belegen diese methodische Schwäche deutlich: Wenn das Ausblenden vermeintlich relevanter Bildbereiche die Modellkonfidenz sogar erhöht, ist die Erklärung falsch und stellt im klinischen Einsatz ein kritisches Sicherheitsrisiko dar. Der Grund hierfür ist primär das *Out-of-Distribution*-Problem. Das flächige Maskieren der Superpixel erzeugt unnatürliche Bildartefakte, auf die das Modell mangels entsprechender Trainingsdaten mit unberechenbaren Vorhersagen reagiert. Um solche Effekte künftig methodisch sauber zu isolieren, bieten sich Ansätze wie ROAR (*RemOve And Retrain*) [56] an, die das Netzwerk auf den modifizierten Daten neu trainieren, sowie tiefergehende *Sanity Checks*.

Die deutlich geringere Erklärungstreue von Grad-CAM auf dem MobileNetV3 lässt sich theoretisch auf dessen spezielle Architektur zurückführen. Eine plausible Hypothese ist, dass die komprimierenden *Depthwise Separable Convolutions* [26] den für Grad-CAM essenziellen Gradientenfluss verzerren. Da im Rahmen dieser Arbeit jedoch kein empirischer Vergleich der Gradientennormen zwischen den Schichten beider Architekturen durchgeführt wurde, bleibt dieser Erklärungsansatz zunächst eine theoretische Überlegung. Um diese Hypothese abschließend zu validieren, bedarf es zukünftiger Forschungsarbeiten, die den exakten Gradientenfluss innerhalb derartiger effizienter Netzwerkarchitekturen quantitativ untersuchen.

Die gemessenen Effektstärken ($|r_{rb}| = 0,549$ beim ResNet-101 und $|r_{rb}| = 0,746$ beim MobileNetV3) belegen hierbei, dass diese Modellabhängigkeit keine statistische Anomalie der Stichprobengröße ist, sondern spürbare Auswirkungen auf die Qualität der Diagnose hat.

Zusammenfassend belegen diese Erkenntnisse, dass in der dermatologischen Bildklassifikation keine universelle Standardlösung für Erklärbarkeitsmethoden existiert. Die Verlässlichkeit und Treue einer Erklärung ist stets das Resultat einer gezielten Abstimmung zwischen der gewählten Modellarchitektur und dem eingesetzten XAI-Verfahren.

6.2.3 Recheneffizienz und klinische Anwendbarkeit

Teilfrage 3: Welche der beiden Methoden bietet den besseren Kompromiss aus Recheneffizienz und Verständlichkeit im Hinblick auf einen potenziellen klinischen Einsatz?

Basierend auf den experimentellen Ergebnissen lässt sich diese Frage klar beantworten: Grad-CAM bietet für den medizinischen Alltag den geeigneteren Kompromiss.

Hinsichtlich der Recheneffizienz erweist sich Grad-CAM, wie die Messungen in Kapitel 5.4 belegen, als nahezu echtzeitfähig. Anerkannte Richtlinien wie die *Clinical XAI Guidelines* fordern klar: Die Erstellung einer KI-Erklärung darf zeitkritische Diagnosen nicht verzögern. Die Wartezeit muss für das ärztliche Personal zumutbar bleiben [18].

Während Grad-CAM diese Anforderung problemlos erfüllt, summieren sich die rechenintensiven Durchläufe der Methode LIME bei einem vollständigen Hautkrebs-Screening zu Wartezeiten, die für einen Point-of-Care-Einsatz am Patientenbett unpraktikabel sind.

Hinsichtlich der Verständlichkeit und medizinischen Verlässlichkeit liefert LIME durch die Segmentierung in Superpixel theoretisch eine sehr klare Erklärung. Die Robustheitsanalysen (vgl. Kapitel 5.2) haben in Übereinstimmung mit der bestehenden Literatur gezeigt, dass die Methode instabil auf winziges Rauschen oder minimale Bildveränderungen reagiert. [16]. Eine Heatmap, die bei fast identischen Aufnahmen stark schwankt, verwirrt den behandelnden Arzt mehr, als dass sie den Diagnoseprozess unterstützt. Im Gegensatz dazu liefert Grad-CAM verlässliche und stabile Ergebnisse. Aufgrund der Instabilität und der unpraktikablen Rechenzeit scheidet LIME für den klinischen Alltag aus. Den besseren Kompromiss für ein medizinisches Assistenzsystem bildet Grad-CAM in Kombination mit dem ResNet-101, da diese Konfiguration in Sekundenbruchteilen robuste Visualisierungen bereitstellt.

MODELLARCHITEKTUR	EVALUIERUNGSKRITERIEN	GRAD-CAM	LIME
ResNet-101 (Klassisch, tief)	Erklärungstreue (IROF) (Höher = besser)	82,71	75,31
	Robustheit (Lipschitz) (Niedriger = besser)	0,40	3,52
	Recheneffizienz (Zeit pro Bild)	~0,016 s	~4,43 s
MobileNetV3 (Verschlankt, effizient)	Erklärungstreue (IROF) (Höher = besser)	65,67	76,56
	Robustheit (Lipschitz) (Niedriger = besser)	0,64	3,94
	Recheneffizienz (Zeit pro Bild)	~0,012 s	~2,20 s

Tabelle 10: Zusammenfassende Entscheidungsmatrix. Eine Gegenüberstellung von Grad-CAM und LIME anhand der Parameter Erklärungstreue, Robustheit und Effizienz, getrennt nach Modellarchitektur.

6.3 Qualitative Erkenntnisse und der "Clever Hans"-Effekt

Die in Kapitel 5.5 präsentierten qualitativen Sanity Checks verdeutlichen den klinischen Wert von Explainable AI, insbesondere bei der Fehleranalyse. Wie die visuellen Ergebnisse der Fehlklassifikationen zeigen, stützen tiefe neuronale Netze ihre Vorhersagen nicht immer auf das Erlernen echter Läsionsmerkmale. Stattdessen zeigte die Inspektion der Heatmaps, dass sich die Modelle in bestimmten Fällen fälschlicherweise auf Störfaktoren im Hintergrund, wie etwa Körperbehaarung oder ärztliche Hautmarkierungen fokussierten.

Um zu verstehen, warum dieses Verhalten für die medizinische KI so trügerisch ist, lohnt ein Blick auf die Ursprünge des sogenannten „Clever Hans“-Effekts [12]. Der Begriff geht auf das Pferd „Kluger Hans“ zurück, das Anfang des 20. Jahrhunderts Bekanntheit erlangte.

Das Tier schien komplexe mathematische Aufgaben lösen zu können, indem es die Ergebnisse mit den Hufen klopfte. Erst spätere psychologische Untersuchungen von Oskar Pfungst zeigten, dass das Pferd in Wahrheit über keine Rechenfähigkeiten verfügte. In Wahrheit reagierte das Tier lediglich auf minimale, unbewusste Gesten oder Bewegungen seines Trainers. Das Pferd löste die Aufgaben also nicht selbst, sondern nutzte unabsichtliche Hinweise aus seinem Umfeld, um zur richtigen Antwort zu kommen [12].

In der heutigen künstlichen Intelligenz beschreibt dieser Effekt dasselbe Phänomen: Ein Deep-Learning-Modell erreicht scheinbar hohe Ergebnisse, stützt sich dabei in Wahrheit aber auf irrelevante Störfaktoren oder Artefakte in den Trainingsdaten [12]. Ein prominentes Beispiel der XAI-Forschung von Lapuschkin et al. (2019) [12] belegt dies: Ein Modell, das auf die Erkennung von Pferden trainiert wurde, identifizierte die Tiere nicht anhand ihrer anatomischen Merkmale. Stattdessen achtete es nahezu ausschließlich auf ein Wasserzeichen am linken unteren Bildrand, das zufällig auf vielen Pferdebildern im Datensatz platziert war. Solange das Wasserzeichen im Bild war, erkannte die KI ein Pferd – selbst wenn das Bild eigentlich ein Auto zeigte. Auch in der dermatologischen Bildanalyse ist diese Gefahr real. So weisen beispielsweise Winkler et al. (2019) [62] darauf hin, dass neuronale Netze dazu neigen, sich bei der Klassifikation von Hautläsionen an chirurgischen Hautmarkierungen oder Linealen zu orientieren, anstatt die eigentliche Läsion zu bewerten, was ebenfalls ein klassisches Clever-Hans-Verhalten darstellt.

Im Kontext dieses „Clever Hans“-Effekts muss zudem das angewendete Oversampling von bis zu 300 % für Minderheitsklassen kritisch reflektiert werden. Obwohl die Bildkopien augmentiert wurden (z. B. durch Rotationen), bleiben darauf abgebildete Störfaktoren wie Lineale oder Hautmarkierungen bestehen. Das Modell sieht diese identischen Artefakte somit überproportional oft in Verbindung mit seltenen Klassen, was das Risiko birgt, dass es sie fälschlicherweise als prädiktive Merkmale erlernt.

Dieser Umstand unterstreicht die Notwendigkeit von XAI, da solch schwerwiegenden Fehlentwicklungen bei einer reinen Überprüfung der Trefferquote vollkommen unentdeckt blieben.

An diesem Punkt zeigt sich die zentrale Aussage dieser Arbeit, die auch im Titel „Vertrauen durch Validierung“ steckt. Oft wird argumentiert, dass Explainable AI vor allem Vertrauen in Black-Box-Modelle aufbauen soll. Die qualitativen Ergebnisse zeigen eine weitere wichtige Funktion: XAI warnt aktiv vor falschem Vertrauen. Ein Modell mit hoher Genauigkeit suggeriert dem Arzt hohe Zuverlässigkeit. Wenn diese Genauigkeit aber auf einem „Clever Hans“-Muster beruht, ist dieses Vertrauen unbegründet und potenziell gefährlich.

Dass die getesteten XAI-Methoden dieses falsche Lernverhalten sichtbar machen können, ist für die Praxis wertvoll. Ärzte werden so vor einer trügerischen Sicherheit bewahrt und können KI-Entscheidungen kritisch hinterfragen. Zusammenfassend zeigen die Ergebnisse, dass ein verlässlicher Einsatz der KI-gestützten Dermatologie über die bloße Betrachtung von Metriken hinausgehen muss und eine Validierung der erzeugten Heatmaps erfordert.

6.4 Limitationen der Arbeit

Trotz des kontrollierten experimentellen Aufbaus unterliegt die durchgeführte Evaluation gewissen Einschränkungen, die bei der Interpretation der Ergebnisse bedacht werden müssen. Aufgrund der massiven rechnerischen Komplexität von LIME, bei denen die Rauschempfindlichkeit in tausenden Iterationen geprüft werden muss, wurde die Stichprobengröße für die Metrik-Berechnung auf 32 Bilder begrenzt. Obwohl dieses Vorgehen in der aktuellen Literatur zur XAI-Evaluation als Standardpraxis zur Umgehung von Hardware-Flaschenhälsen anerkannt ist [15], ließe sich die Aussagekraft der Ergebnisse durch eine Auswertung des gesamten Testdatensatzes weiter erhöhen. Zudem beschränkte sich die Arbeit auf zwei spezifische CNNs.

Eine methodische Limitation ist die isolierte Messung der Robustheit über den *Local Lipschitz Estimate*, der lediglich das Worst-Case-Szenario abbildet. Es bleibt somit aus den vorliegenden Daten unklar, ob die gemessene Instabilität von LIME systematisch ist oder primär auf extremen Ausreißern in der Perturbation beruht.

Zudem muss die inhaltliche Aussagekraft von Heatmaps kritisch eingeordnet werden. Zwar erfüllen sie das Kriterium der Lokalisierung, sie erklären jedoch nicht die Semantik der Entscheidung. Der Arzt erkennt, wo das Modell Auffälligkeiten erkennt, erfährt jedoch nicht, ob das Modell dort medizinische Muster (wie ein Pigmentnetzwerk) oder lediglich irrelevante Kontraste erkannt hat. Wie Lipton (2016) [5] sowie Jin et al. (2023) [18] betonen, besteht bei einer reinen Visualisierung die Gefahr einer trügerischen Transparenz, die eine echte medizinische Begründung nicht vollständig ersetzen kann.

7. Fazit und Ausblick

Dieses Kapitel fasst die zentralen empirischen Erkenntnisse der vorliegenden Arbeit zusammen, ordnet den praktischen Nutzen für die klinische Dermatologie ein und leitet daraus konkrete Anknüpfungspunkte für zukünftige Forschungsarbeiten ab.

7.1 Zusammenfassende Schlussfolgerungen der XAI-Evaluation

Die Ergebnisse dieser Arbeit zeigen deutlich, dass man KI-Systemen in der Medizin nicht allein deshalb vertrauen darf, weil sie auf dem Papier hohe Genauigkeitswerte erreichen. Für eine verlässliche Überprüfung in der Praxis reicht es aber auch nicht aus, nur auf die mathematischen Messwerte der XAI-Methoden zu schauen. Eine echte Validierung muss immer aus zwei Teilen bestehen: einer rechnerischen und einer visuellen Prüfung.

Die quantitative Untersuchung hat gezeigt, dass die Erklärungstreue davon abhängt, wie gut das XAI-Verfahren und das jeweilige KI-Modell zusammenpassen. Bei komplexen Modellen wie dem ResNet-101 liefern interne Berechnungen über die Gradienten (Grad-CAM) die besten Ergebnisse. Bei schlanken Modellen wie dem MobileNetV3 dagegen können diese internen Gradienten zu Fehlern führen, weshalb man hier auf von außen ansetzende Methoden wie LIME zurückgreifen sollte. Mathematische Kennzahlen wie der IROF-Score sind also unverzichtbar, um die grundlegende Logik der Erklärungen objektiv zu messen und grobe Fehler zu erkennen.

Diese Zahlen allein können jedoch täuschen. Wie die visuelle Überprüfung der Heatmaps in Kapitel 5.5/5.6 zeigt, sagt ein guter mathematischer Wert noch nichts darüber aus, ob die KI auch aus den richtigen medizinischen Gründen entscheidet. Erst der Blick auf die Bilder legt offen, ob das Modell echte Läsionsmerkmale der Haut analysiert oder ob sich die Vorhersage auf medizinisch irrelevante Artefakte stützt. Ohne diese qualitative Kontrolle bleibt das große Risiko unentdeckt, dass die Netzwerke im Sinne des „Clever Hans“-Effekts lediglich auf Störfaktoren reagieren.

Zusammenfassend lässt sich sagen: Belastbares Vertrauen in der KI-gestützten Dermatologie entsteht weder durch bloße Genauigkeit noch durch reine Statistik bei der Erklärbarkeit. Erst wenn die objektiven Messwerte durch eine kritische visuelle Kontrolle der Heatmaps bestätigt werden, können diese Systeme sicher in den medizinischen Alltag integriert werden.

7.2 Klinische Implikationen und der Wert der Erklärbarkeit

Für die medizinische Praxis ergibt sich aus der vorangegangenen Evaluation eine klare Präferenz: Im Rahmen eines dermatologischen Hautkrebs-Screenings müssen oft Dutzende Läsionen eines einzelnen Patienten in kürzester Zeit beurteilt werden. Latenzzeiten von mehreren Sekunden pro Bild stören den Arbeitsablauf erheblich und überschreiten die tolerierbare Wartezeit. Grad-CAM bietet hier in Kombination mit dem ResNet-101 den deutlich besseren Kompromiss aus Effizienz und Transparenz und ist für den schnellen klinischen Alltag prädestiniert.

Um die Akzeptanz solcher Assistenzsysteme zu gewährleisten, darf die KI den Arzt jedoch nicht bevormunden, sondern muss als transparenter „Second Reader“ agieren.

Obwohl sich Grad-CAM in Kombination mit dem ResNet-101 als die zuverlässigste und effizienteste XAI-Lösung erwiesen hat, erfordern die Hardware-Limitierungen im klinischen Alltag ein flexibleres Vorgehen. Um die Stärken beider evaluierter Modellarchitekturen optimal zu nutzen, ohne die Arzt-Patienten-Interaktion zu stören, lässt sich ein zweistufiges Interaktionskonzept skizzieren:

1. **Point-of-Care Triage durch ein mobiles Hand-Dermatoskop:** Für die erste Untersuchung am Patienten empfiehlt sich ein digitales Hand-Dermatoskop, das mit einem effizienten Klassifikationsmodell (wie dem MobileNetV3) ausgestattet ist. Sobald der Arzt die Läsion im Sichtfeld zentriert, erfolgt die Analyse. Da der Blick zwingend am Patienten bleiben muss, gibt das Gerät ein unmittelbares auditives Feedback: Erkennt das Modell mit sehr hoher Konfidenz (z. B. $> 95\%$) eine eindeutig ein klassisches Muttermal, ertönt ein unauffälliges Bestätigungssignal. Fällt die Konfidenz geringer aus oder besteht der Verdacht auf maligne Strukturen, wird ein warnendes Signal ausgegeben.
2. **Feindiagnostik und Konfidenz-Validierung am Monitor:** Wurde eine Läsion durch das MobileNetV3 als auffällig eingestuft, wechselt der Arzt an den stationären Arbeitsplatzrechner. Hier übernimmt nun das leistungsstarke ResNet-101 die finale Analyse. Dort präsentiert eine Software-Oberfläche die Aufnahme im Detail und zeigt explizit den berechneten Konfidenzwert der KI an (ein visueller Entwurf dieser Benutzeroberfläche findet sich als Mockup in Anhang A.2). Um diesen Wert nicht blind übernehmen zu müssen, wird direkt unter dem Originalbild die XAI-Heatmap eingeblendet. Da die Wartezeit den klinischen Workflow nicht behindern darf, generiert Grad-CAM hierbei die Erklärungen in Sekundenbruchteilen. Der Arzt kann durch diese Visualisierung sofort beurteilen, ob die ausgegebene Modell-Konfidenz gerechtfertigt ist oder ob das Modell fälschlicherweise auf Hintergrundartefakte (wie Haare oder Markierungen) fokussiert.

Letztlich zeigt sich, dass XAI weit über das rein technische Debugging hinausgeht. Es ist eine wesentliche Voraussetzung, um KI-Modelle als nützliche ärztliche Helfer sicher, ethisch vertretbar und effizient einzusetzen, ohne dabei die endgültige Verantwortung aus der Hand des Arztes zu geben.

Die quantitative Validierung führt damit auch zurück zu den rechtlichen Anforderungen, die in der Einleitung genannt wurden. Die DSGVO fordert bei automatisierten Diagnosen ausdrücklich ein Recht auf Erklärbarkeit. Die Ergebnisse dieser Arbeit zeigen jedoch, dass dieses Recht nicht schon dadurch erfüllt ist, dass irgendeine XAI-Methode genutzt wird. Liefert eine Methode wie LIME instabile Erklärungen, entstehen gefährliche Grauzonen bei der Haftung. Eine verlässliche Transparenz – wie sie hier bei der Kombination aus ResNet-101 und Grad-CAM gemessen wurde – ist daher die Voraussetzung, um medizinische KI-Systeme überhaupt rechtssicher in den Praxisalltag zu integrieren.

7.3 Zukünftiger Forschungsbedarf (Ausblick)

Für zukünftige Forschungsarbeiten ergeben sich aus diesen Erkenntnissen mehrere konkrete Anknüpfungspunkte.

Erstens sollte die quantitative Evaluation auf hochaktuelle, echtzeitfähige Transformer-Architekturen ausgeweitet werden. Ein Beispiel hierfür ist der LW-DETR (Light-Weight Detection Transformer), der klassische faltungsbasierte Netzwerke in Effizienz und Präzision übertrifft [63]. Hierbei bleibt zu prüfen, ob sich die in dieser Arbeit beobachteten Unterschiede zwischen gradienten- und perturbationsbasierten Ansätzen auch auf moderne Netzwerke übertragen lassen.

Zweitens limitierte die hohe Rechenintensität von LIME die Stichprobengröße der Metrik-Evaluation in dieser Arbeit auf einen kleinen Batch von 32 Bildern. Mit zukünftigen, leistungstärkeren Hardware-Ressourcen wäre eine Skalierung dieser quantitativen Evaluation auf den gesamten Testdatensatz erstrebenswert, um die statistische Belastbarkeit der Robustheits- und Erklärungstreue-Werte weiter zu festigen. In diesem Zuge sollte zudem ergänzend die *Average Sensitivity* [39] erhoben werden, um neben dem Worst-Case-Szenario auch die durchschnittliche Störanfälligkeit der Methoden zu quantifizieren.

Drittens sollte die methodische Weiterentwicklung den Fokus auf konzeptbasierte Erklärbarkeit, insbesondere auf sogenannte *Concept Bottleneck Models (CBMs)*, legen [64]. CBMs adressieren dieses Problem, indem sie das Netzwerk zwingen, als Zwischenschritt menschlich definierte und verständliche medizinische Konzepte vorherzusagen. Durch lässt sich die Black-Box-Diagnostik für Anwender deutlich transparenter gestalten.

7. Fazit und Ausblick

Letztlich muss der tatsächliche medizinische Mehrwert von XAI-Methoden durch umfangreiche *Human-in-the-Loop*-Studien validiert werden. Es bleibt in der Praxis zu erforschen, wie Dermatologen ihre eigenen Diagnosen durch die Unterstützung von Heatmaps im direkten Praxisalltag verbessern können und inwiefern sich diese Systeme auf das Vertrauen und die ärztliche Entscheidungsfindung bei potenziell widersprüchlichen KI-Vorhersagen auswirken.

Anhang

A.1 Quellcode und Reproduzierbarkeit

Der vollständige Quellcode (Jupyter Notebook) zur Reproduktion aller in dieser Arbeit präsentierten quantitativen Ergebnisse, generierten Grafiken und trainierten Modellgewichte ist im folgenden öffentlichen GitHub-Repository hinterlegt:

Link zum Repository: <https://github.com/jallewa/Thesis-Vertrauen-durch-Validierung/tree/4a8c8a0ea73f9a8a2e952810f7ab4c2a91bacd02>

A.2 Entwurf der klinischen Software-Oberfläche (Mockup)

Die nachfolgenden Abbildungen visualisieren exemplarisch das in Kapitel 7.2 skizzierte Konzept eines XAI-gestützten Assistenzsystems für die dermatologische Feindiagnostik (Stufe 2). Links die Originalaufnahme dargestellt. Darunter liegt die via Grad-CAM generierte Heatmap zur visuellen Überprüfung der Modell-Fokussierung. Auf der rechten Seite erfolgt die Ausgabe der Modell-Diagnose inklusive der berechneten Konfidenz.




Abbildung A.1: Exemplarisches Mockup der Benutzeroberfläche mit einem negativen Ergebnis.




Abbildung A.2: Exemplarisches Mockup der Benutzeroberfläche mit einem positiven Ergebnis.

Generierung:

Die Abbildungen A.1 und A.2 wurden am 10.06.2026 dialogbasiert mit der KI <https://app.banani.co/> erstellt. Der Ablauf war wie folgt:

- **Initialer Start-Prompt:** Aufbau des Mockups: Oben Links: Das Original-Hautbild (aus dem HAM10000 Datensatz). Mitte Links: Die Grad-CAM Heatmap, über das Originalbild gelegt. Rechts (Das Dashboard): Klassifikation: Verdacht auf Malignes Melanom (mel) Konfidenz/Sicherheit: Ein großer Balken oder Tacho, der z. B. auf 87 % steht. Modell-Warnhinweise:) Ein kleines Feld unter der Heatmap: "Hinweis: Das Modell weist eine hohe Aktivierung am Bildrand (mögliche Artefakte) auf. Bitte Diagnose durch Heatmap verifizieren.
- **Rückfrage der KI** nach dem gewünschten Stil. Ich wählte: klinisch/medizinisch
- **Folge-Prompt:** -Oben links in der Ecke das Icon, den Titel (DermAI Analyzer) und den Untertitel "v1.0..." entfernen. -Als Modell statt EfficientzNet-B3 (Ensemble) bitte ResNet-101. - Die Warnbox mit "Hohes Risiko" entfernen. - Das Wort Konfidenz ist nach unten abgeschnitten - Der Subtext unter dem Titel "Verdacht auf malignen Befund..." entfernen
- **Folge-Prompt:** Nun noch oben rechts in der Ecke den Badge mit "ResNet-50" entfernen
- **Folge-Prompt:** Das Element mit dem Bildtext "HAM10000 - ISIC_0024306" entfernen. - Und man kann die 0 und 100 nicht gut erkennen, da sie teilweise auf den Prozent-Anzeigebalken liegen - Teilen Button entfernen
- **Folge-Prompt:** Erstelle genau das gleiche Bild nur mit einem positiven Befund "Melanozytärer Nävus"

Literaturverzeichnis

- [1] A. Esteva, B. Kuprel, R. A. Novoa, J. Ko, S. M. Swetter, H. M. Blau und S. Thrun, „Dermatologist-level classification of skin cancer with deep neural networks,“ *Nature* 542, p. 115–118, 2017.
- [2] N. C. F. Codella, D. Gutman, M. E. Celebi, B. Helba, M. A. Marchetti, S. W. Dusza, A. Kalloo, K. Liopyris, N. Mishra, H. Kittler und A. Halpern, „Skin lesion analysis toward melanoma detection: A challenge at the 2017 International symposium on biomedical imaging (ISBI), hosted by the international skin imaging collaboration (ISIC),“ *2018 IEEE 15th International Symposium on Biomedical Imaging (ISBI 2018)*, pp. 168–172, 2018.
- [3] P. Tschandl, C. Rosendahl und H. Kittler, „The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions,“ *Scientific Data* 5, 180161, 2018.
- [4] S. S. Han, G. H. Park, W. Lim, M. S. Kim, J. I. Na, I. Park und S. E. Chang, „Deep neural networks show an equivalent and often superior performance to dermatologists in onychomycosis diagnosis,“ *PLoS ONE* 13(1): e0191493, 2018.
- [5] Z. C. Lipton, „The Mythos of Model Interpretability,“ *arXiv preprint arXiv:1606.03490*, 2016.
- [6] J. Amann, A. Blasimme, E. Vayena, D. Frey und V. I. Madai, „Explainability for artificial intelligence in healthcare: a multidisciplinary perspective,“ *BMC Medical Informatics and Decision Making* 20, 310, 2020.
- [7] A. Holzinger, C. Biemann, C. S. Pattichis und D. B. Kell, „What do we need to build explainable AI systems for the medical domain?,“ *arXiv preprint arXiv:1712.09923*, 2017.
- [8] F. Doshi-Velez und B. Kim, „Towards A Rigorous Science of Interpretable Machine Learning,“ *arXiv preprint arXiv:1702.08608*, 2017.
- [9] C. Patrício, J. C. Neves und L. Teixeira, „Explainable Deep Learning Methods in Medical Image Classification: A Survey,“ *ACM Computing Surveys, Volume 54, Issue 4*, pp. 1–41, 2023.
- [10] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh und D. Batra, „Grad-CAM: Visual explanations from deep networks via gradient-based localization,“ *In Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, p. 618–626, 2017.
- [11] M. T. Ribeiro, S. Singh und C. Guestrin, „“Why Should I Trust You?”: Explaining the Predictions of Any Classifier,“ *In Proceedings of the 22nd ACM SIGKDD*

- International Conference on Knowledge Discovery and Data Mining*, p. 1135–1144, 2016.
- [12] S. Lapuschkin, S. Wäldchen, A. Binder, G. Montavon, W. Samek und K.-R. Müller, „Unmasking Clever Hans predictors and assessing what machines really learn,“ *Nature Communications* 10, 1096, 2019.
 - [13] P.-J. Kindermans, S. Hooker, J. Adebayo, M. Alber, K. T. Schütt, S. Dähne, D. Erhan und B. Kim, „The (Un)reliability of saliency methods,“ *arXiv preprint arXiv:1711.00867*, 2017.
 - [14] J. Adebayo, J. Gilmer, M. Muelly, I. Goodfellow, M. Hardt und B. Kim, „Sanity checks for saliency maps,“ *In Advances in Neural Information Processing Systems* 31, p. 9505–9515, 2018.
 - [15] H. Sangwan, „Quantifying Explainable AI Methods in Medical Diagnosis: A Study in Skin Cancer,“ *medRxiv*, 2024.
 - [16] D. Alvarez-Melis und T. S. Jaakkola, „On the Robustness of Interpretability Methods,“ *arXiv preprint arXiv:1806.08049*, 2018.
 - [17] R. Daneshjou, C. Barata, B. Betz-Stablein, E. Celebi, N. Codella, M. Combalia, P. Guitera, D. Gutman, A. Halpern, B. Helba, H. Kittler, K. Kose, K. Liopyris, J. Malvehy, H. S. Seog, P. Soyer, E. R. Tkaczyk, P. Tschandl und V. Rotemberg, „Checklist for Evaluation of Image-Based Artificial Intelligence Reports in Dermatology: CLEAR Derm Consensus Guidelines From the International Skin Imaging Collaboration Artificial Intelligence Working Group,“ *JAMA Dermatology*, 158(1), p. 90–96, 2022.
 - [18] W. Jin, X. Li, M. Fatehi und G. Hamarneh, „Guidelines and evaluation of clinical explainable AI in Medical Image Analysis,“ *arXiv preprint arXiv: 2202.10553*, 2023.
 - [19] Y. LeCun, L. Bottou, Y. Bengio und P. Haffner, „Gradient-based learning applied to document recognition,“ *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
 - [20] J. T. Springenberg, A. Dosovitskiy, T. Brox und M. Riedmiller, „Striving for Simplicity: The All Convolutional Net,“ *arXiv preprint arXiv:1412.6806*, 2015.
 - [21] N. Tajbakhsh, J. Y. Shin, S. R. Gurudu, T. Hurst, C. B. Kendall, M. B. Gotway und J. Liang, „Convolutional neural networks for medical image analysis: Full training or fine tuning?,“ *IEEE Transactions on Medical Imaging*, 35(5), p. 1299–1312, 2016.
 - [22] A. Chattopadhyay, A. Sarkar, P. Howlader und V. N. Balasubramanian, „Grad-CAM++: Generalized Gradient-Based Visual Explanations for Deep

- Convolutional Networks," *2018 IEEE Winter Conference on Applications of Computer Vision (WACV)*, pp. 839-847, 2018.
- [23] I. Goodfellow, Y. Bengio und A. Courville, „Deep Learning," 2016. [Online]. Available: <http://www.deeplearningbook.org>. [Zugriff am 04 2026].
- [24] K. He, X. Zhang, S. Ren und J. Sun, „Deep residual learning for image recognition," *Proceedings of the IEEE conference on computer vision and pattern recognition*, p. 770–778, 2016.
- [25] Q. Han, X. Qian, H. Xu, K. Wua, L. Meng, Z. Qiu, T. Weng, B. Zhou und X. Gao, „DM-CNN: Dynamic Multi-scale Convolutional Neural Network with uncertainty quantification for medical image classification," *Computers in Biology and Medicine*, 2023.
- [26] A. G. Howard, M. Sandler, G. Chu, L.-C. Chen, B. Chen, M. Tan, W. Wang, Y. Zhu, R. Pang, V. Vasudevan, Q. V. Le und H. Adam, „Searching for MobileNetV3," *IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 1314-1324, 2019.
- [27] F. Chollet, „Xception: Deep learning with depthwise separable convolutions," *In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, p. 1800–1807, 2017.
- [28] J. Hu, L. Shen und G. Sun, „Squeeze-and-Excitation Networks," *In Proceedings of the IEEE conference on computer vision and pattern recognition*, p. 7132–7141, 2018.
- [29] U. K. Lilhore, S. Simaiya, Y. K. Sharma, K. S. Kaswan, B. Rao, M. Rao, A. Baliyan, A. Bijalwan und R. Alroobaea, „A precise model for skin cancer diagnosis using hybrid U-Net and improved MobileNet-V3 with hyperparameters optimization," *Scientific Reports*, 14, p. 4299, 2024.
- [30] S. Ali, M. Sipon, H. Jahurul und R. Mahbubur, „An enhanced technique of skin cancer classification using deep convolutional neural network with transfer learning models," *Machine Learning with Applications*, 5, 100036, 2021.
- [31] S. J. Pan und Q. Yang, „A survey on transfer learning," *IEEE Transactions on Knowledge and Data Engineering*, 22(10), p. 1345–1359, 2009.
- [32] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li und L. Fei-Fei, „ImageNet: A large-scale hierarchical image database," *In 2009 IEEE conference on computer vision and pattern recognition*, p. 248–255, 2009.
- [33] A. Krizhevsky, I. Sutskever und G. E. Hinton, „ImageNet classification with deep convolutional neural networks," *In Advances in Neural Information Processing Systems*, p. 1097–1105, 2012.

- [34] B. Zhou, A. Khosla, A. Lapedriza, A. Oliva und A. Torralba, „Learning deep features for discriminative localization,“ *Proceedings of the IEEE conference on computer vision and pattern recognition*, p. 2921–2929, 2016.
- [35] L. Zou, H. L. Goh, C. J. Y. Liew, J. L. Quah, G. T. Gu, J. J. Chew,, M. P. Kumar, C. G. L. Ang und A. W. An Ta, „Ensemble Image Explainable AI (XAI) Algorithm for Severe Community-Acquired Pneumonia and COVID-19 Respiratory Infections,“ *IEEE Transactions on Artificial Intelligence*, Vol 4, No 2, pp. 242-254, 2023.
- [36] S. M. Lundberg und S.-I. Lee, „A Unified Approach to Interpreting Model,“ in *Advances in Neural Information Processing Systems*, Bd. 30, I. Curran Associates, Hrsg., 2017.
- [37] M. Sundararajan, A. Taly und Q. Yan, „Axiomatic Attribution for Deep Networks,“ *Proceedings of the 34th International Conference on Machine Learning*, Vol. 70, pp. 3319-3328, 2017.
- [38] D. Smilkov, N. Thorat, B. Kim, F. Viégas und M. Wattenberg, „SmoothGrad: removing noise by adding noise,“ *arXiv preprint arXiv:1706.03825v1*, 2017.
- [39] C.-K. Yeh, C.-Y. Hsieh, A. S. Suggala, D. I. Inouye und P. Ravikumar, „On the (In)fidelity and Sensitivity of Explanations,“ *In Advances in Neural Information Processing Systems 32*, 2019.
- [40] L. Rieger und L. K. Hansen, „IROF: a low resource evaluation metric for explanation methods,“ *arXiv preprint arXiv:2003.08747*, 2020.
- [41] A. Rab Ratul, H. Mozaffari, W.-S. Lee und E. Parimbelli, „Skin Lesions Classification Using Deep Learning Based on Dilated Convolution,“ *bioRxiv*, 2020.
- [42] A. A. Adegun und S. Viriri, „FCN-Based DenseNet Framework for Automated Detection and Classification of Skin Lesions in Dermoscopy Images,“ *IEEE Access*, 8, 150377–150396, 2020.
- [43] K. Hasan, T. E. Elahi, A. Alam, T. Jawad und R. Martí, „DermoExpert: Skin lesion classification using a hybrid convolutional neural network through segmentation, transfer learning, and augmentation,“ *Informatics in Medicine Unlocked*, 28, 100819, 2022.
- [44] I. A. Alfi, M. M. Rahman, M. Shorfuzzaman und A. Nazir, „A Non-Invasive Interpretable Diagnosis of Melanoma Skin Cancer Using Deep Learning and Ensemble Stacking of Machine Learning Models,“ *Diagnostics*, 12(3), 726, 2022.
- [45] N. V. Chawla, K. W. Bowyer, L. O. Hall und W. P. Kegelmeyer, „SMOTE: Synthetic Minority Over-sampling Technique,“ *Journal of Artificial Intelligence Research*, 16, p. 321–357, 2002.

- [46] M. Hossain, M. Hossain, B. Arefin, F. Akhtar und J. Blake, „Combining State-of-the-Art Pre-Trained Deep Learning Models: A Noble Approach for Skin Cancer Detection Using Max Voting Ensemble,“ *Diagnostics*, 14(1), 89, 2024.
- [47] L. Perez und J. Wang, „The effectiveness of data augmentation in image classification using deep learning,“ *arXiv preprint arXiv:1712.04621*, 2017.
- [48] Y. Bengio, „Practical recommendations for gradient-based training of deep architectures,“ *In Neural Networks: Tricks of the Trade*, p. 437–478, 2012.
- [49] D. P. Kingma und J. L. Ba, „Adam: A method for stochastic optimization,“ *arXiv preprint arXiv:1412.6980*, 2014.
- [50] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever und R. Salakhutdinov, „Dropout: A simple way to prevent neural networks from overfitting,“ *Journal of Machine Learning Research*, 15(1), p. 1929–1958, 2014.
- [51] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Köpf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai und S. Chintala, „PyTorch: An imperative style, high-performance deep learning library,“ *In Advances in Neural Information Processing Systems 32*, 2019.
- [52] M. Abadi, P. Barham, J. Chen, Z. Chen, A. Davis, J. Dean, M. Devin, S. Ghemawat, G. Irving, M. Isard, M. Kudlur, J. Levenberg, R. Monga, S. Moore, D. G. Murray, B. Steiner, P. Tucker, V. Vasudevan, P. Warden, M. Wicke, Y. Yu und X. Zheng, „TensorFlow: Large-scale machine learning on heterogeneous distributed systems,“ *arXiv preprint arXiv:1603.04467*, 2016.
- [53] N. Kokhlikyan, V. Miglani, M. Martin, E. Wang, B. Alsallakh, J. Reynolds, A. Melnikov, N. Kliushkina, C. Araya, S. Yan und O. Reblitz-Richardson, „Captum: A unified and generic model interpretability library for PyTorch,“ *arXiv preprint arXiv:2009.07896*, 2020.
- [54] A. Hedström, L. Weber, D. Bareeva, D. Krakowczyk, F. Motzkus, W. Samek, S. Lapuschkin und M. M.-C. Höhn, „Quantus: An Explainable AI Toolkit for Responsible Evaluation of Neural Network Explanations and Beyond,“ *Journal of Machine Learning Research*, 24(34), p. 1–11, 2023.
- [55] S. Bach, A. Binder, G. Montavon, F. Klauschen, K.-R. Müller und W. Samek, „On pixel-wise explanations for non-linear classifier decisions by layer-wise relevance propagation,“ *PLoS ONE*, 10(7): e0130140, 2015.
- [56] S. Hooker, D. Erhan, P.-J. Kindermans und B. Kim, „A Benchmark for Interpretability Methods in Deep Neural Networks,“ *In Advances in Neural Information Processing Systems 32*, 2019.

- [57] L. A. de Souza, R. Mendel, S. Strasser, A. Ebigbo, A. Probst, H. Messmann, J. P. Papa und C. Palm, „Convolutional Neural Networks for the evaluation of cancer in Barrett's esophagus: Explainable AI to lighten up the black-box,“ *Computers in Biology and Medicine*, Vol. 135, p. 104578, 2021.
- [58] F. Wilcoxon, „Individual Comparisons by Ranking Methods,“ *Biometrics Bulletin*, 1(6), p. 80–83, 1945.
- [59] J. Cohen, *Statistical power analysis for the behavioral sciences*, 1988.
- [60] D. S. Kerby, „The Simple Difference Formula: An Approach to Teaching Nonparametric Correlation,“ *Comprehensive Psychology*, 3, 11-17, 2014.
- [61] R. R. Hoffman, S. T. Mueller, G. Klein und J. Litman, „Metrics for explainable AI: challenges and prospects,“ *CoRR*, abs/1812.04608, 2018.
- [62] J. K. Winkler, C. Fink, F. Toberer, A. Enk, T. Deinlein, R. Hofmann-Wellenhof, L. Thomas, A. Lallas, A. Blum, W. Stolz und H. A. Haenssle, „Association between surgical skin markings in dermoscopic images and diagnostic performance of a deep learning convolutional neural network for melanoma recognition,“ *JAMA Dermatology*, p. 1135–1141, 2019.
- [63] Q. Chen, X. Su, X. Zhang, J. Wang, J. Chen, Y. Shen, C. Han, Z. Chen, W. Xu, F. Li, S. Zhang, K. Yao, E. Ding, G. Zhang und J. Wang, „LW-DETR: A Transformer Replacement to YOLO for Real-Time Detection,“ *arXiv preprint arXiv:2406.03459v1*, 2024.
- [64] P. W. Koh, T. Nguyen, Y. S. Tang, S. Mussmann, E. Pierson, B. Kim und P. Liang, „Concept Bottleneck Models,“ *Proceedings of the 37th International Conference on Machine Learning*, vol. 119, pp. 5338-5348, 2020.